

# 概率论 课堂笔记

原生生物

斗满人概，人满天概。——管子

## 目录

一 概率空间与独立性	2
§1.1 事件与概率	2
§1.2 条件概率与独立性	3
§1.3 概率模型	4
二 随机变量与分布函数	5
§2.1 随机变量	5
§2.2 随机向量	6
三 离散型随机变量	7
§3.1 分布列与独立性	7
§3.2 数学期望	8
§3.3 协方差	10
§3.4 条件分布与条件期望	11
§3.5 随机游走	11
§3.6 母函数	13
四 连续型随机变量	14
§4.1 独立性	14
§4.2 期望	15
§4.3 多元正态分布	17
五 中心极限定理	18
§5.1 一般随机变量的期望	18
§5.2 特征函数	19
§5.3 反转与连续性定理	21
§5.4 极限定理	22
六 几种收敛	24
§6.1 四种收敛方式	24
§6.2 重要结论	26
§6.3 强大数律	27

七 概率论外篇	27
§7.1 信息熵 . . . . .	27
§7.2 Linderberg 替换理论 . . . . .	28
§7.3 随机矩阵 . . . . .	29

## 一 概率空间与独立性

### §1.1 事件与概率

样本点-具体结果 样本空间  $\Omega$ -样本点的全体 事件  $A$ -样本空间的子集

例 1.1 掷硬币  $\Omega = \{H, T\}, A = \{H\}$

电子自旋  $\Omega = \{\uparrow, \downarrow\}, A = \{\uparrow\}$

掷骰子  $\Omega = \{1, 2, 3, 4, 5, 6\}, A = \{2, 4, 6\}$

\* 上方的例子中, 样本点均只有有限多个。

例 1.2 道琼斯指数 样本点-连续曲线  $x(t), t \in [0, T]$  样本空间  $\Omega = \{x(t) \in C[0, T]\}$

事件运算  $\longleftrightarrow$  集合运算

事件  $A$  发生  $\longleftrightarrow$  试验结果  $\omega \in A$

$A = \emptyset$  不可能事件  $A = \Omega$  必然事件

事件交、并、余  $\longleftrightarrow A \cap B, A \cup B, A^c$

事件的交-两事件均发生 事件的并-两事件至少发生一个 事件的余-事件未发生

\* 可记  $A \cap B$  为  $AB$

$A$  与  $A^c$  称对立事件。

$A$  发生则  $B$  亦发生  $\longleftrightarrow A \subset B$

$A \cap B = \emptyset$  时称  $A, B$  不相容。

\* 由此亦可定义  $A_1, \dots, A_n, \dots$  互不相容

问题: 是否要将  $\Omega$  的所有子集定义为随机事件?

\* 良好定义的随机事件为  $\Omega$  的一个子集族, 且至少要求对交、并、余三种运算封闭。

例 1.3 掷硬币第一次正面向上的时刻  $\Omega = \{1, 2, \dots\}$  此时样本空间为无限集合, 有限交并性质不足!

定义 1.1  $\mathcal{F}$  为  $\Omega$  某些子集构成的子集族, 称其为事件域 ( $\sigma$  域), 若:

1.  $\Omega \in \mathcal{F}$

2.  $A \in \mathcal{F} \implies A^c \in \mathcal{F}$

3.  $A_n \in \mathcal{F}, n \in \mathbb{N}^* \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$

并称  $(\Omega, \mathcal{F})$  为一个可测空间。

例 1.4 最大  $\sigma$  域,  $\Omega$  的幂集

最小  $\mathcal{F} = \{\Omega, \emptyset\}$

中间域, 如  $A \neq \emptyset, \Omega$  时  $\mathcal{F} = \{\Omega, \emptyset, A, A^c\}$

定义概率: 直观想法-频率稳定性 (重复试验后计数发生次数)

重复  $N$  次,  $A$  发生  $N_A$  次, 经验表明  $\lim_{N \rightarrow \infty} \frac{N_A}{N} = c$ , 记  $c$  为  $P(A)$ 。明显性质:  $P(\emptyset) = 0, P(\Omega) = 1$ 。

若  $A \cap B = \emptyset, N_{A \cup B} = N_A + N_B \implies P(A \cup B) = P(A) + P(B)$

定义 1.2  $P: \mathcal{F} \rightarrow \mathbb{R}$  为  $(\Omega, \mathcal{F})$  上的概率测度, 若:

1. 非负性  $P(A) \geq 0$

2. 规范性  $P(\Omega) = 1$

3. 可列可加性 若  $\{A_n\}$  互不相容, 则  $P\left(\bigcup_n A_n\right) = \sum_n P(A_n)$

并称  $(\Omega, \mathcal{F}, P)$  为一个概率空间。

例 1.5 掷硬币  $\Omega = \{H, T\}, \mathcal{F} = 2^\Omega, P(\{H\}) = p, P(\{T\}) = q, p + q = 1$

例 1.6  $\Omega = \{1, 2, 3, 4, 5, 6\}, \mathcal{F} = 2^\Omega$  假定公平, 则  $P(A) = \frac{|A|}{6}$

样本点有限, 且每个样本点等概率发生, 则称**古典概型**。

**定理 1.1** 概率测度基本性质

1.  $P(A^c) = 1 - P(A)$
2.  $A \subset B$  时  $P(B) = P(B \setminus A) + P(A) \geq P(A)$
3.  $P(A \cup B) = P(B) + P(A) - P(AB)$
4. *Jordan* 公式  $P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n \sum_{i_1 < \dots < i_k} (-1)^{k-1} P(A_{i_1} \dots A_{i_k})$

**定理 1.2** 概率测度连续性

1. 单调增事件列  $A_1 \subset \dots \subset A_n \subset \dots$ , 记  $A = \bigcup_{i=1}^{\infty} A_i = \lim_{n \rightarrow \infty} A_n$ , 则  $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ 。
2. 单调减事件列  $B_1 \supset \dots \supset B_n \supset \dots$ , 记  $B = \bigcap_{i=1}^{\infty} B_i = \lim_{n \rightarrow \infty} B_n$ , 则  $P(B) = \lim_{n \rightarrow \infty} P(B_n)$ 。

证明:  $A = A_1 \cup (A_2 \setminus A_1) \cup \dots \cup (A_n \setminus A_{n-1}) \cup \dots$ 。此处的并均为无交并, 因此可由定义与引理计算即得结果。对于  $B$ , 取余即可化为  $A$  的情况。

## §1.2 条件概率与独立性

直观想法-重复试验,  $B$  发生  $N_B$  次,  $B$  发生条件下  $A$  发生次数  $N_{AB}$ , 次数足够多时**条件概率**可看作  $\frac{N_{AB}}{N_B}$ 。

**定义 1.3** 条件概率

设  $P(B) > 0$ ,  $B$  发生条件下  $A$  的条件概率  $P(A|B) = \frac{P(AB)}{P(B)}$

变形有乘法公式  $P(AB) = P(B)P(A|B)$

\* $B_1, \dots, B_n$  为  $\Omega$  的互不相容子集, 且  $\bigcup_i B_i = \Omega$ , 则称其为  $\Omega$  的一个**划分**。

**定理 1.3** 全概率公式

$B_1, \dots, B_n$  为  $\Omega$  的一个划分,  $P(B_i) > 0$ , 则  $A = A \cap \Omega = \bigcup_i (B_i \cap A) \Rightarrow P(A) = \sum_i P(B_i)P(A|B_i)$ 。

例 1.7 坛子里有 3 白 2 红共 5 个球, 每次无放回摸出一个球,  $A = \{\text{第二次摸到白球}\}$ , 按第一次抽到白或红划分可知  $P(A) = \frac{3}{5} \cdot \frac{1}{4} + \frac{2}{5} \cdot \frac{3}{4} = \frac{3}{5}$  (注意到, 在每个轮次抽出白球的概率一致)。

**定理 1.4** 贝叶斯公式

$A_1, \dots, A_n$  为  $\Omega$  的一个划分,  $P(A_i) > 0$ , 则  $P(B) > 0$  时  $P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_j P(A_j)P(B|A_j)}$

例 1.8 发出  $s$  时, 收到  $s$  概率为 0.8, 收到  $t$  概率为 0.2; 发出  $t$  时, 收到  $s$  概率为 0.1, 收到  $t$  概率为 0.9。且发出  $s$  概率为 0.6, 发出  $t$  概率为 0.4。

收到  $s$  的情况下, 发出  $s$  的概率为:  $\frac{0.6 \cdot 0.8}{0.6 \cdot 0.8 + 0.4 \cdot 0.1} = 0.923$

掷硬币,  $B$  代表第一次正面,  $A$  代表第二次正面, 则  $P(A|B) = P(A)$ , 即  $P(AB) = P(A)P(B)$ , 由此引出定义:

**定义 1.4 独立性**

称  $A, B$  独立, 若  $P(AB) = P(A)P(B)$

更一般, 称  $A_1, \dots, A_n$  相互独立是指  $\forall 2 \leq k \leq n, i_1 < \dots < i_k, P(\prod_{j=1}^k A_{i_j}) = \prod_{j=1}^k P(A_{i_j})$ ;

两两独立是指只需  $k=2$  时满足。

两两独立与相互独立不同, 举例如下:

**例 1.9** 古典概型中,  $\Omega = \{1, 2, 3, 4\}, A = \{1, 3\}, B = \{1, 2\}, C = \{1, 4\}$ 。

计算可知  $A, B, C$  两两独立, 但不相互独立。

**定理 1.5** 若  $A, B$  独立, 则  $A$  与  $B^c$ ,  $A^c$  与  $B$ ,  $A^c$  与  $B^c$  独立。更一般地, 若一些事件相互独立, 将其中部分改为其对立事件后仍然相互独立。

证明: 两事件时, 由对称, 只需证明  $A$  与  $B^c$  独立。由  $P(AB^c) + P(AB) = P(A)$  可算出结果。多事件时类似两事件一个个调整即可。

**例 1.10 “重复独立试验, 小概率事件必发生”**

记事件为  $A$ ,  $A_k = \{\text{第 } k \text{ 次试验中 } A \text{ 发生}\}$ , 则  $\bigcup_{k=1}^n A_k$  表示  $\{\text{前 } n \text{ 次试验中 } A \text{ 发生}\}$ 。

$P(\bigcup_{k=1}^n A_k) = 1 - P(\bigcap_{k=1}^n A_k^c)$ , 由独立性, 此式为  $1 - \prod_{k=1}^n (1 - P(A_k))$ , 由此知结果。

**§1.3 概率模型****例 1.11 对称随机游走**

赌徒财富  $k$ , 庄家  $N - k$ , 掷均匀硬币, 正面则赌徒赢庄家 1, 否则庄家赢赌徒 1, 赌至一方输光, 问赌徒输光概率。

记赌徒初始为  $k$  且输光的事件为  $A_k$ ,  $B$  为首局正面, 由此  $P(A_k) = P(B)P(A_k|B) + P(B^c)P(A_k|B^c) = \frac{P(A_{k-1}) + P(A_{k+1})}{2}$ , 且  $P(A_0) = 1, P(A_N) = 0$ , 由等差数列知  $P(A_k) = \frac{N-k}{N}$ 。

**计数问题**

**例 1.12** 坛子里有 4 白 6 红共 10 个球, 随机取 4 个, 求 2 白 2 红概率。

样本点数目  $C_{10}^4$ , 事件发生的样本点数目  $C_4^2 C_6^2$ , 结果为  $\frac{3}{7}$ 。

\* 古典概型重要应用: 排列组合计算样本点数目

经典问题:  $n$  个对象中选  $m$  个, 问选法种数 (是否可重复? 是否考虑顺序?)。

有序不重复:  $A_n^m$  无序不重复:  $C_n^m$  有序可重复:  $n^m$

无序可重复: 插板法, 看作  $m$  个小球  $n$  个盒子 ( $n-1$  个挡板), 知结果为  $C_{n-1+m}^m$

**例 1.13** 将  $n$  个小球投入到  $N \geq n$  个盒子中, 投法等可能, 求前  $n$  个盒子中各一个球的概率 (球是否可分辨? 盒子是否有容量限制?)。

(1) 球可区分, 盒子无限制 (麦克斯韦-玻尔兹曼统计): 样本点个数  $N^n$ , 合要求个数  $n!$ , 概率  $\frac{n!}{N^n}$

(2) 球不可区分, 盒子无限制 (玻色-爱因斯坦统计): 化为无序可重复, 样本点个数  $C_{n+N-1}^n$ , 合要求个数 1, 概率  $\frac{1}{C_{n+N-1}^n}$

(3) 球不可区分, 盒子容量一 (费米-狄拉克统计): 样本点个数  $C_N^n$ , 合要求个数 1, 概率为  $\frac{1}{C_N^n}$

**例 1.14 Polya 模型**

坛子里有一些球,  $b$  黑  $r$  红, 先摸出一个记下颜色后放回, 并且再放入  $c$  个同色球。记  $B_n$  表示第  $n$  次抽到黑球, 求概率。

观察可发现,  $n$  次抽取抽中  $k$  次黑球, 任意给定次序概率相同, 为  $D_k(b) = \frac{\prod_{i=0}^{k-1} (b+ic) \prod_{i=0}^{n-k-1} (r+ic)}{\prod_{i=0}^{n-1} (b+r+ic)}$ ,

有  $B_{n+1} = \sum_{k=0}^n C_n^k D_k(b) \frac{b+kc}{b+r+nc} = \frac{b}{b+r} \sum_{k=0}^n C_n^k D_k(b+r)$ , 而由概率含义  $\sum_{k=0}^n C_n^k D_k(b+r)$  构成整个样

本空间, 因此为 1, 因此  $B_{n+1} = \frac{b}{b+r}$ 。

\* $c = -1$  即为无放回,  $c = 0$  即为有放回。

## 二 随机变量与分布函数

### §2.1 随机变量

$\mathcal{F}_1, \mathcal{F}_2$  为  $\Omega$  上的  $\sigma$  域, 可验证其交亦为  $\sigma$  域。更一般地, 给定某指标集  $I$ ,  $\mathcal{F}_i, i \in I$  的交集亦为  $\sigma$  域。

$\mathbb{R}$  上 Borel 域定义为包含所有  $(a, b], a, b \in \mathbb{R}$  的最小  $\sigma$  域 (最小定义: 所有包含的取交), 记为  $B(\mathbb{R})$ 。

$\{b\} = \bigcap_n \left(b - \frac{1}{n}, b\right] \in B(\mathbb{R})$ , 类似知  $(a, b), [a, b], [a, b) \in B(\mathbb{R})$ 。

$B(\mathbb{R}^n)$  为包含所有左开右闭区间笛卡尔积形成的矩形的最小  $\sigma$  域, Borel 域中的集合称 Borel 集。

#### 定义 2.1 随机变量、概率分布函数

$(\Omega, \mathcal{F}, P)$  中, 称  $X: \Omega \rightarrow \mathbb{R}$  为一个随机变量, 若  $\forall x \in \mathbb{R}$ , 有  $\{\omega \in \Omega: X(\omega) \leq x\} \in \mathcal{F}$ 。

此时记后方集合为  $\{X \leq x\}$ , 称  $F(x) = P(\{X \leq x\})$  为随机变量  $X$  的 (概率) 分布函数。

**例 2.1 掷均匀硬币**

$\Omega = \{H, T\}, X: \Omega \rightarrow \mathbb{R}, X(H) = 1, X(T) = -1$

$$P(\{X \leq x\}) = \begin{cases} 1 & x \geq 1 \\ 0.5 & -1 \leq x < 1 \\ 0 & x < -1 \end{cases}$$

#### 定理 2.1 分布函数 $F(x)$ 性质

1. 单调增

2. 负无穷极限 0, 正无穷极限 1

3. 右连续  $\lim_{\sigma \rightarrow 0^+} F(x + \sigma) = F(x)$

证明:

1. 利用包含关系说明。

2. 取一列数趋向正/负无穷, 利用概率的极限等于极限的概率知结论。

3. 类似 2, 取子列说明。

注:

(1) 若某函数这三条性质, 一定为某随机变量的概率分布函数, 因此, 一般将满足三条性质的函数称为分布函数。

(2) 另一种定义分布函数的方式:  $G(x) = P(\{X < x\})$ , 此时其具有左连续性, 一二两条不变。

(3) 分布函数丢失了关于样本空间的信息, 与样本空间无关。

**例 2.2** 若  $X = c$  概率为 1, 称  $X$  几乎处处常值, 则  $F(x) = \begin{cases} 1 & x \geq c \\ 0 & x < c \end{cases}$

**例 2.3** Bernoulli 两点分布

若  $P(X=1)=p, P(X=0)=q, p+q=1$ , 则  $F(x) = \begin{cases} 1 & x \geq 1 \\ q & 0 \leq x < 1 \\ 0 & x < 0 \end{cases}$

特别地,  $A \in \mathcal{F}$ , 示性函数  $I_A(\omega) = \begin{cases} 1 & \omega \in A \\ 0 & \omega \notin A \end{cases}$  亦为随机变量, 满足 Bernoulli 两点分布, 且有  $P(I_A = 1) = P(A)$ 。

**定理 2.2** 随机变量性质

1.  $P(X > x) = 1 - F(x)$
2.  $P(x < X \leq y) = F(y) - F(x)$
3.  $P(X = x) = F(x) - F(x^-)$

**定理 2.3** 设  $X$  为  $(\Omega, \mathcal{F}, P)$  上随机变量, 则任意 Borel 集的原象为事件域中元素。

证明: 记  $\mathcal{A} = \{A \subset \mathbb{R} : X^{-1}(A) \in \mathcal{F}\}$ , 由于  $X^{-1}(A^c) = X^{-1}(A)^c, X^{-1}\left(\bigcup_n A_n\right) = \bigcup_n X^{-1}(A_n)$  分别验证三条性质可知  $\mathcal{A}$  为  $\mathbb{R}$  上  $\sigma$  域。因此,  $(a, b] = (-\infty, b] - (-\infty, a] \in \mathcal{A}$ , 进一步可知  $B(\mathbb{R}) \subset \mathcal{A}$ , 即可得证。

\* 随机变量相加后仍为随机变量

证明: 令  $r_n$  为一切有理数的一个排列, 证出  $\{X+Y \leq x\} = \bigcap_{n=1}^{\infty} (\{X \leq r_n\} \cup \{Y \leq x - r_n\})$  即可说明结论。

右包含左易证, 故只需证明  $\omega$  不属于左侧时亦不属于右侧。若其不属于左侧, 取  $m$  使  $X(\omega) > r_m > Y(\omega)$  即发现其不属于右侧。

**§2.2 随机向量****定义 2.2** 离散型随机变量

随机变量  $X$  取值至多可列个  $x_1, x_2, \dots$ , 则称  $X$  为离散型随机变量。

记  $p_k = P(X = x_k)$ , 则  $\{p_k\}$  为  $X$  的分布列, 此时分布函数  $F(x) = \sum_{k: x_k \leq x} p_k$  在  $x_k$  处跳跃, 又称原子分布。

**定义 2.3** 连续型随机变量

若随机变量  $X$  的分布函数  $F(x) = \int_{-\infty}^x f(u)du$ , 其中  $f$  非负可积, 则称  $X$  为连续型随机变量, 称  $f$  为  $X$  的密度函数。

注:

- (1) 密度函数含义: 当  $x = x_0$  为  $f$  连续点时,  $\Delta x \rightarrow 0$ , 则  $P(x_0 < X \leq x_0 + \Delta x) = f(x_0)\Delta x$ 。
- (2) 密度函数改变有限多个值仍为密度函数。
- (3)  $P(X = a) \leq \int_{a-1/n}^a f(u)du \rightarrow 0$ , 因此  $X$  在任意有限多个点取值概率为 0。
- (4) 若  $F$  连续且除去有限多个点外  $F'(x)$  存在且连续, 则  $X$  为连续型随机变量, 且  $F'$  可作为一个密度函数。
- (5)  $X$  为连续型随机变量, 则  $F$  绝对连续。

**例 2.4** 钟表指针

$\Omega = [0, 2\pi), \mathcal{F} = B(\mathbb{R}) \cap \Omega, P(A) = \frac{|A|}{2\pi}, |A|$  指勒贝格测度。

令  $X(\omega) = \omega, Y(\omega) = \omega^2$ , 则

$$F_X(x) = \begin{cases} x < 0 & 0 \\ \frac{x}{2\pi} & x \in (0, 2\pi] \\ x \geq 2\pi & 1 \end{cases}, F_Y(x) = \begin{cases} x < 0 & 0 \\ \frac{\sqrt{y}}{2\pi} & x \in (0, 4\pi^2] \\ x \geq 4\pi^2 & 1 \end{cases}, \text{求导知 } f_X, f_Y.$$

分布函数  $F$  性质:

(1) 单调  $\rightarrow$  不连续点至多可数

(2) 勒贝格分解  $F = c_1 F_d + c_2 F_c + c_3 F_s$  其中  $c_i \geq 0, \sum_i c_i = 1$ ,  $F_d$  为离散型随机变量的分布函数,  $F_c$  为连续型随机变量的分布函数,  $F_s$  为奇异的。

**定义 2.4** 随机向量

$X_1, \dots, X_n$  为  $(\Omega, \mathcal{F}, P)$  上的随机变量, 称  $\vec{X} = (X_1, \dots, X_n)$  为  $n$  维随机向量,  $F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$  为  $\vec{X}$  的联合分布函数。

离散型:  $\vec{X}$  取值至多可列多个, 联合分布列  $f(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$ 。

连续型:  $F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(u_1, \dots, u_n) du_1 \dots du_n$ ,  $f$  非负可积, 称  $f$  为  $X$  的联合密度函数。

**定理 2.4** 考虑二维随机向量的联合分布函数  $F(x, y)$ :

1.  $F(x, y)$  关于  $x, y$  均单调增。

2.  $F(x, y)$  关于  $x, y$  均右连续。

3.  $F(x, y)$  在  $x, y$  趋近负无穷时极限均为 0,  $x, y$  均趋近正无穷时极限为 1。

4.  $x_1 \leq x_2, y_1 \leq y_2$  时  $F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) = P(X \in (x_1, x_2], Y \in (y_1, y_2]) \geq 0$

注:

(1) 取极限可发现 4 蕴含 1, 反之不然 (举例:  $F(x) = \begin{cases} 1 & x+y \geq 0 \\ 0 & x+y < 0 \end{cases}$  满足 1,2,3 但不满足 4)。

(2) 若某二元函数满足 2,3,4 三条性质, 一定为某随机向量的联合分布函数。

$F_X(x) = P(X \leq x) = \lim_{y \rightarrow +\infty} F(x, y)$  称为边缘分布。

连续型随机变量  $F_X(x) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(u, v) dv du$ ,  $f_X(x) = \int_{-\infty}^{+\infty} f(x, v) dv$  称为边缘密度。

**例 2.5** 三项分布

$\Omega = \{H, T, E\}$ , 均匀“三面硬币”, 设扔  $n$  次后三种次数分别为  $H_n, T_n, E_n$ , 有  $H_n + E_n + T_n = n$ , 则

$$P((H_n, T_n, E_n) = (h, t, e)) = \frac{n!}{h!t!e!} \frac{1}{3^n}$$

**例 2.6**  $G \subset \mathbb{R}^n$  为有限区域, 则联合密度函数  $f(x_1, \dots, x_n) = \frac{1}{|G|}, \vec{x} \in G$

特别地,  $G = [0, 1]^2$  时,  $f(x, y) = \begin{cases} 1 & (x, y) \in G \\ 0 & (x, y) \notin G \end{cases}$

## 三 离散型随机变量

### §3.1 分布列与独立性

回顾: 离散型随机变量  $X$  取值至多可列个  $x_1, x_2, \dots$ , 记  $p_k = P(X = x_k)$ , 则  $\{p_k\}$  为  $X$  的分布列。



**例 3.1** 二项分布

$P(X = k) = C_n^k p^k q^{n-k}, p + q = 1$  时称  $X$  符合二项分布, 记为  $X \sim B(n, p)$ 。

背景: 抛  $n$  次硬币,  $X$  为正面向上次数,

**例 3.2** 几何分布

$P(X = k) = q^{k-1}p, p + q = 1$  时称  $X$  符合几何分布, 此时  $P(X > k) = q^k$ 。

背景: 抛  $n$  次硬币,  $X$  为第一次正面向上时抛的次数。

几何分布具有无记忆性:  $P(X - m = k | X > m) = P(X = k)$ 。反之, 若取值为  $\mathbb{N}^*$  的某随机变量满足无记忆性, 即对任意  $m, k$  符合上式, 则必须服从几何分布。

**例 3.3** 泊松分布

$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \lambda > 0$  时称  $X$  符合泊松分布, 记为  $X \sim P(\lambda)$ 。

背景: 网站访问量、百科新词条

\* 放射性粒子数: 体积为  $V$  的小物块分为  $n$  等份, 每一小块  $\Delta v = \frac{V}{n}$ , 假设每一小块在 7.5s 内放出 1 个  $\alpha$  粒子的概率为  $p = \mu \cdot \Delta v$ , 放出更多概率为 0, 且各小块放出与否相互独立。

分析:  $n$  块共放出  $k$  个概率符合二项分布, 令  $\lambda = \mu V$ , 则

$P(X = k) = C_n^k p^k (1-p)^{n-k} = \frac{n \cdots (n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$ , 固定  $k$ , 令  $n$  趋向无穷, 此式极限即为  $\frac{\lambda^k}{k!} e^{-\lambda}$ 。由此可知, 二项分布可以逼近泊松分布。

**定义 3.1** 独立性

若  $\forall x, y \in \mathbb{R}, P(X = x, Y = y) = P(X = x)P(Y = y)$ , 则称离散型随机变量  $X, Y$  独立。

更一般, 称  $X_1, \dots, X_n$  相互独立, 若  $\forall x_i \in \mathbb{R}, P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$ 。

**定理 3.1** 离散型随机变量  $X, Y$  独立, 当且仅当  $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y) \Leftrightarrow F(x, y) = F_X(x)F_Y(y)$ 。

证明: 利用分布列  $f(x, y)$  与分布函数  $F(x, y)$  关系, 利用求和可证明仅当, 利用左极限可证明当。

**例 3.4** 泊松翻转

抛均匀硬币 1 次, 记  $X, Y$  为正反出现的次数, 计算容易发现不独立。

抛  $N$  枚均匀硬币,  $N \sim P(\lambda)$ , 计算  $f(x, y) = P(X = x, Y = y, N = x + y) = \frac{\lambda^{x+y}}{(x+y)!} e^{-\lambda} \frac{C_{x+y}^x}{2^{x+y}}$   
 $= \left(\frac{\lambda}{2}\right)^x \frac{e^{-\lambda/2}}{x!} \left(\frac{\lambda}{2}\right)^y \frac{e^{-\lambda/2}}{y!}$ , 注意到  $f_X(x) = \sum_y f(x, y) = \left(\frac{\lambda}{2}\right)^x \frac{e^{-\lambda/2}}{x!}$ , 由此知  $X, Y$  独立。

**定理 3.2** 离散型随机变量  $X, Y$  独立,  $g, h$  是  $\mathbb{R}$  上的 Borel 可测函数, 则  $g(X), h(Y)$  独立。

证明:  $P(g(X) = a, h(Y) = b) = P\left(\bigcup_{g(x)=a} \{X = x\}, \bigcup_{h(y)=b} \{Y = y\}\right)$  分解求和。

**§3.2 数学期望****定义 3.2** 数学期望

离散型随机变量  $X$  对应分布列  $f$ ,  $\sum_{x: f(x) > 0} x f(x)$  若绝对收敛, 则称为  $X$  的数学期望, 记为  $E[X]$ 。

\*  $E[x] = \sum_k x_k p_k$  (原则上  $x_i$  互不相同, 事实上相同不会影响计算)

**定理 3.3** 佚名统计学家公式

$g$  为  $\mathbb{R}$  上函数,  $Y = g(X)$ ,  $X$  分布列为  $f$ , 则  $E[Y] = \sum_x g(x)f(x)$  (假定右侧绝对收敛)。

证明: 考虑  $Y$  分布列即可。

**定义 3.3** 数字特征

离散型随机变量  $X$  的  $k$  阶矩为  $m_k = E[X^k]$ ,  $k$  阶中心矩  $\sigma_k = E[(X - m_1)^k]$ 。

方差  $\text{Var}(X)$  为二阶中心矩,  $\text{Var}(X) = \sum_x (x - m_1)^2 f(x) = E[X^2] - 2m_1 E[X] + m_1^2 = E[X^2] - E^2[X]$ 。

标准差定义为  $\sqrt{\text{Var}(X)}$

**例 3.5** Bernoulli 分布

$P(X = 1) = p, P(X = 0) = q, p + q = 1 \Rightarrow E[X] = p, \text{Var}(X) = p - p^2 = pq$

**例 3.6** 二项分  $X \sim B(n, p)$ 

$$E[X] = \sum_{k=0}^n k C_n^k p^k q^{n-k} = np \sum_{k=0}^{n-1} C_{n-1}^k p^k q^{n-1-k} = np$$

$$E[X(X-1)] = \sum_{k=0}^n k(k-1) C_n^k p^k q^{n-k} = n(n-1)p^2$$

$$E[X^2] = np(np + q), \text{Var}(X) = npq$$

**定理 3.4** 数学期望性质

1. 非负性:  $X \geq 0 \Rightarrow E[X] \geq 0$

2. 归一性:  $E[1] = 1$

3. 线性性:  $E[aX + bY] = aE[X] + bE[Y]$

由此,  $E$  可以看作一个期望算子。

线性性证明: 令示性函数  $A_x = \{X = x\}$ , 则  $X = \sum_x x I_{A_x}$ ,  $E[X] = \sum_x x P(A_x)$ , 对  $Y$  用  $B_y$  类似处理,

$$\text{则 } aX + bY = \sum_x x I_{A_x} + \sum_y y I_{B_y} = \sum_{Ax+By} I_{A_x} I_{B_y}.$$

\* 观点: 扩展至量子物理、非线性期望

**定理 3.5**  $X, Y$  独立且期望存在,  $E[XY] = E[X]E[Y]$ 。

$$\text{证明: } E[X] = \sum_x x I_{A_x}, E[Y] = \sum_y y I_{B_y} \Rightarrow E[X]E[Y] = \sum_{x,y} xy I_{A_x} I_{B_y}.$$

**定理 3.6** 方差性质

1.  $\text{Var}(aX + b) = a^2 \text{Var}(X)$

2.  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2(E(XY) - E(X)E(Y))$ ,  $X, Y$  独立时即可加。

**例 3.7** 期望不存在的例子

$$P(X = x_k) = \frac{1}{2^k}, x_k = (-1)^k \frac{2^k}{k}, \text{ 不绝对收敛, } \sum_k x_k p_k = -\ln 2, \text{ 而期望不存在。}$$

若  $P(X = x_k) = 2^{k-1}$ , 可发现期望趋向于无穷。

## §3.3 协方差

**例 3.8** 考虑一个随机的  $n$  元置换  $\pi$ , 记不动点  $\pi(x) = x$  的个数为  $N$ , 求分布列  $P(N=r), r=0, 1, \dots, n$ .  
 记  $A_k = \{k \text{ 为不动点}\}$ , 对应的示性函数为  $I_k$ , 令  $X = \sum_{i_1 < \dots < i_r} I_{i_1} I_{i_2} \dots I_{i_r} (1 - I_{i_{r+1}}) \dots (1 - I_{i_n})$ , 其中  $i_k$  为 1 到  $n$  的排列, 则  $X = I_{\{N=r\}}$ .

$$E[X] = C_n^r E[I_1 \dots I_r (1 - I_{r+1}) \dots (1 - I_n)] = C_n^r \sum_{s=0}^{n-r} (-1)^s C_{n-r}^s \frac{(n-r-s)!}{n!} = \frac{1}{r!} \sum_{s=0}^{n-r} \frac{(-1)^s}{s!}$$

**例 3.9** 不计算分布列, 求上例中的期望与方差。

$$N = I_1 + I_2 + \dots + I_n. \text{ 则 } E[N] = nE[I_1] = n \frac{(n-1)!}{n!} = 1, E[N^2] = \sum_{i,j=1}^n E[I_i I_j] = nE[I_1^2] + n(n-1)E[I_1 I_2] = 1 + 1 = 2, \text{Var}(N) = 1.$$

**例 3.10** Erdos 概率方法: 正 17 边形染红 5 个顶点, 证明存在 7 个相邻顶点中至少有 3 个红点。

建立模型, 17 个点中等概率随机取一个, 令  $I_k$  为  $k$  为红色的示性函数, 再令  $X(k) = I_{k+1} + \dots + I_{k+7}$ , 则  $E[X] = \frac{35}{17} > 2$ , 由此  $P(X > 2) > 0$ , 得证。

类似随机变量的情况, 对随机向量有结论:  $f(x, y)$  为  $(X, Y)$  的联合分布列,  $g: \mathbb{R}^2 \rightarrow \mathbb{R}$  的 Borel 可测函数, 则  $E[g(X, Y)] = \sum_{x,y} g(x, y) f(x, y)$  (假定右侧绝对收敛)。

**定义 3.4** 协方差与相关系数

协方差  $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$

相关系数  $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$ , 为 0 时称两变量不相关。

\* 对  $n$  维随机向量  $\vec{X} = (X_1, \dots, X_n)$ , 协方差矩阵  $\Sigma = (\sigma_{ij}), \sigma_{ij} = \text{Cov}(X_i, X_j)$

性质: 协方差矩阵对称且非负定。

非负定性证明:  $\sum_{i,j} t_i t_j \sigma_{ij} = \sum_{i,j} t_i t_j E[(X_i - E[X_i])(X_j - E[X_j])] = E \left[ \left( \sum_i t_i (X_i - E[X_i]) \right)^2 \right] \geq 0$

**定理 3.7** 相关系数性质

1.  $|\rho| \leq 1$
2.  $X, Y$  独立或不相关  $\Leftrightarrow \rho = 0$
3.  $\rho = \pm 1 \Leftrightarrow P(Y = aX + b) = 1$

**定理 3.8** Cauchy 不等式

$(E[XY])^2 \leq E[X^2]E[Y^2]$ , 等号成立当且仅当存在不全为 0 实数  $a, b$  使得  $P(aX = bY) = 1$ 。

证明: 先利用佚名统计学家公式说明  $E[X^2] = 0$  时可推出  $P(X = 0) = 1$ , 从而计算得  $E[XY] = 0$ ; 若  $E[X^2] > 0$ ,  $E[(Y - tX)^2] = t^2 E[X^2] - 2tE[XY] + E[Y^2] \geq 0$ , 利用判别式得证, 取等时再利用  $E[X^2] = 0$  的条件即可。

**例 3.11** 多项分布

$\vec{X} = (X_1, \dots, X_r), P(X_1 = k_1, \dots, X_r = k_r) = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$ , 其中  $\sum_i p_i = 1, \sum_i k_i = n$ 。

计算  $\text{Cov}(X_i, X_j), \rho(X_i, X_j)$ 。

$i \neq j$  时  $X_i \sim B(n, p_i), X_i + X_j \sim B(n, p_i + p_j)$ , 由此  $E[X_i] = np_i, \text{Var}(X_i) = np_i(1 - p_i), \text{Var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j)$ , 利用定理 3.6 可知  $\text{Cov}(X, Y) = \frac{1}{2}(\text{Var}(X + Y) - \text{Var}(X) - \text{Var}(Y)) = -np_i p_j$ ,

相关系数为  $-\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}}$ 。

## §3.4 条件分布与条件期望

## 定义 3.5 条件分布

$(X, Y)$  为离散型随机向量, 给定  $X = x$ , 且  $P(X = x) > 0$ ,  $Y$  的条件分布列  $f_{Y|X}(y|x) = P(Y = y|X = x)$ , 对应条件分布函数  $F_{Y|X}(y|x) = P(Y \leq y|X = x)$

注:  $\sum_y f_{Y|X}(y|x) = 1$ , 其亦为一个分布函数。

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}, f_X(x) > 0$$

## 定义 3.6 条件期望

给定  $X = x$  下,  $Y$  的条件期望  $\psi(x) = E[Y|X = x] = \sum_y y f_{Y|X}(y|x)$  (假设其绝对收敛), 并称  $\psi(X)$  为  $Y$  关于  $X$  的条件期望, 记为  $E[Y|X]$ 。

## 定理 3.9 全期望公式

$$E[E[Y|X]] = E[Y] \quad * \text{另一种形式: } E[Y] = \sum_x f_X(x) E[Y|X = x]$$

证明:  $E[\psi(X)] = \sum_x \psi(x) f_X(x) = \sum_x f_X(x) \sum_y y f_{Y|X}(y|x) = \sum_{x,y} y f(x, y) = \sum_y y f_Y(y)$ , 注意步骤中交换次序要求绝对收敛。

\* 类似可定义关于事件的条件期望  $E[X|A] = E[X|I_A = 1]$ 。

例 3.12 多项分布的条件期望  $i \neq j, E[X_j|X_i > 0]$ 

利用全期望公式  $E[X_j] = P(X_i = 0)E[X_j|X_i = 0] + P(X_i > 0)E[X_j|X_i > 0]$ 。又由于  $P(X_j = k|X_i = 0) = \frac{P(X_j = k, X_i = 0)}{P(X_i = 0)} = C_n^k \left(\frac{p_j}{1-p_1}\right)^k \left(1 - \frac{p_j}{1-p_1}\right)^{n-k}$ , 因此  $E[X_j|X_i = 0] = \frac{np_j}{1-p_i}$ , 进而算出  $E[X_j|X_i > 0] = \frac{np_j(1 - (1-p_i)^{n-1})}{(1 - (1-p_i)^n)}$

例 3.13 鸟下  $N$  枚蛋,  $N \sim P(\lambda)$ , 每颗蛋独立以概率  $p$  变为小鸟, 记  $K$  为小鸟数, 计算  $E[K|N]$ 、 $E[K]$ 、 $E[N|K]$ 。

记  $q = 1 - p$ , 由于  $f_{K|N}(k|n) = C_n^k p^k q^{n-k}$ , 因此  $E[K|N = n] = np$ , 即  $E[K|N] = Np$ , 进而  $E[K] = E[E[K|N]] = pE[N] = p\lambda$ 。

而  $f_{N|K}(n|k) = \frac{P(N = n, K = k)}{P(K = k)} = \frac{P(K = k|N = n)P(N = n)}{\sum_m P(K = k|N = m)P(N = m)} = \frac{(\lambda q)^{n-k} e^{-\lambda q}}{(n-k)!}$ , 由此  $E[N|K = k] = \sum_{n \geq k} n \frac{(\lambda q)^{n-k} e^{-\lambda q}}{(n-k)!} = \sum_{n \geq 0} (n+k) \frac{(\lambda q)^n e^{-\lambda q}}{n!} = \lambda q + k$ , 即  $E[N|K] = \lambda q + K$ 。

定理 3.10 记  $\psi(X) = E[Y|X]$ ,  $g$  保证所述期望均存在, 则  $E[\psi(X)g(X)] = E[Yg(X)]$ 。

## §3.5 随机游走

$S_0 = a, S_n = S_{n-1} + X_n = S_0 + \sum_{i=1}^n X_i$ ,  $\{X_i\}$  相互独立且同分布, 取值为  $\pm 1$ ,  $P(X_i = 1) = p, P(X_i = -1) = q, p + q = 1$ 。

\* 直线上简单随机游走, 当  $p = \frac{1}{2}$  时称为对称的。

例 3.14 自由随机游走,  $S_0 = a$ , 求  $P(S_n = b)$ , 已知  $2|a+b+n$ 。

设向右游走次数为  $r$ , 向左游走次数为  $l$ , 则  $\begin{cases} r+l=n \\ r-l=b-a \end{cases} \Rightarrow r = \frac{n+b-a}{2}$ , 因此  $P(S_n = b) = C_n^{(n+b-a)/2} p^{(n+b-a)/2} q^{(n-b+a)/2}$

**定理 3.11** 简单随机游走性质

1. 空间齐性  $P(S_n = j + b | S_0 = a + b) = P(S_n = j | S_0 = a)$
2. 时间齐性  $P(S_{n+m} = j | S_m = a) = P(S_n = j | S_0 = a)$
3. 马氏性  $P(S_{m+n} = j | S_0 = j_0, \dots, S_m = j_m) = P(S_{m+n} = j | S_m = j_m)$

\* 要求等式两边有意义

证明：利用  $P(S_n = j | S_0 = a) = P(\sum_{i=1}^n X_i = j - a | S_0 = a)$  转化即可计算得出结果。

**\* 轨道计数**

平面表示  $\{(n, S_n) : n = 0, 1, \dots\}$

记  $N_n(a, b)$  为  $(0, a) \rightarrow (n, b)$  轨道个数,  $N_n^\circ(a, b)$  为  $(0, a) \rightarrow (n, b)$  且访问  $x$  轴至少一次的轨道个数。

**定理 3.12** 反射原理

若  $a, b > 0$ , 则  $N_n^\circ(a, b) = N_n(-a, b)$ 。

证明：寻找第一个交点, 利用一一对应。

**定理 3.13**  $N_n(a, b) = C_n^{(n+b-a)/2}$ 

\* 关心问题：返回出发点、游走最远距离、首次击中某点

**定理 3.14** 投票定理

$b > 0$ , 则  $(0, 0) \rightarrow (n, b)$  不再过  $x$  轴的轨道个数为  $(1, 1) \rightarrow (n, b)$  不过  $x$  轴的轨道个数, 即  $N_{n-1}(1, b) - N_{n-1}^\circ(1, b) = \frac{b}{n} N_n(0, b)$ 。

**例 3.15**  $A$  得票  $a$ ,  $B$  得票  $b < a$ , 求  $A$  得票始终大于  $B$  的概率。

问题可化为  $(0, 0)$  到  $(a+b, a-b)$  轨道中不再过  $x$  轴轨道数与总数之比, 为  $\frac{a-b}{a+b}$ 。

**定理 3.15** 不返回出发点

$S_0 = 0, n \neq 1$ , 则  $P(S_1 \dots S_n \neq 0, S_n = b) = \frac{|b|}{n} P(S_n = b)$ 。

由此可推得  $P(S_1 \dots S_n \neq 0) = \frac{E[|S_n|]}{n}$

证明：利用投票定理计算即可。

\* 记最到达的最右端  $M_n = \max\{S_i : 0 \leq i \leq n\}$ ,  $S_0 = 0 \Rightarrow M_n \geq 0$

**定理 3.16** 最右端

$$P(M_n \geq r, S_n = b) = \begin{cases} P(S_n = b) & b \geq r \\ \left(\frac{q}{p}\right)^{r-b} P(S_n = 2r - b) & b < r \end{cases}$$

证明：考虑第一次到达  $r$  的点, 反射其后的部分, 即可与  $S_n = 2r - b$  的轨道数量一一对应, 而反射产生的概率差别为  $\left(\frac{q}{p}\right)^{r-b}$ 。

\* 推论：  $p = q$  时可以计算出  $P(M_n \geq r) = P(S_n = r) + 2P(S_n \geq r + 1)$ 。

**定理 3.17** 首中时定理

$S_0 = 0$ , 时刻  $n$  首次击中  $b$  概率为  $f_b(n) = \frac{|b|}{n} P(S_n = b)$ 。

证明：不妨设  $b > 0$ ，注意条件等价于  $M_{n-1} = S_{n-1} = b - 1, S_n = b$  即可算出结果。

### 定理 3.18 反正弦律

对称随机游走， $S_0 = 0$ ，记  $T_{2n} = \max\{0 \leq i \leq 2n : S_i = 0\}$ ，则  $P(T_{2n} = 2k) = P(S_{2k} = 0)P(S_{2n-2k} = 0)$

证明：利用  $P(S_{2k+1} \dots S_{2n} \neq 0 | S_{2k} = 0) = P(S_1 \dots S_{2n-2k} \neq 0 | S_0 = 0)$ 。此外  $P(S_1 \dots S_{2m} \neq 0) = P(S_2 \dots S_{2m} \neq 0 | S_1 = 1) = P(\text{第 } 2m \text{ 次后首次击中 } -1)$ ，由此可计算出结论。

\* 此分布称为反正弦律

利用 Stirling 公式可计算  $P(T_n \leq 2xn) \sim \frac{1}{n} \sum_{\frac{k}{n} < x} \frac{1}{\pi} \frac{1}{\sqrt{\frac{k}{n}(1-\frac{k}{n})}} \sim \int_0^x \frac{1}{\pi \sqrt{u(1-u)}} du = \frac{2}{\pi} \arcsin \sqrt{x}, \frac{T_{2n}}{2n}$

渐近分布  $\frac{2}{\pi} \arcsin \sqrt{x}$ 。

$\mathbb{Z}^d$  上的随机游走： $S_n = S_{n-1} + X_n = S_0 + \sum_{i=1}^n X_i$ ，向量  $\{X_i\}$  相互独立且同分布，仅有一个不为 0 且取值为  $\pm 1$  的分量。

例 3.16 平面上对称随机游走，求  $P(S_{2n} = 0)$ 。

考虑上下左右次数知结果为  $\sum_{k=0}^n \frac{(2n)!}{k!k!(n-k)!(n-k)!} \frac{1}{4^{2n}} = C_{2n}^n \frac{1}{4^{2n}} \sum_{k=0}^n (C_n^k)^2 = \frac{1}{4^{2n}} (C_{2n}^n)^2$ 。

## §3.6 母函数

\* 数列的母函数： $\{a_i, i \in \mathbb{N}\}$ ，母函数  $G_a(s) = \sum_{i=0}^{\infty} a_i s^i$ ，如  $C_n^i$  对应  $(1+s)^n$

卷积： $c_n = \sum_{k=0}^n a_k b_{n-k}$ ，记为  $c = a * b$ ，验证有  $G_c(s) = G_a(s)G_b(s)$ 。

例 3.17 随机游走  $S_0 = 0$ ，求  $S_{2n} = 0, S_i \geq 0$  的轨道个数  $C_n$ 。

设首次返回原点为  $2k$  时，则考虑第一步后可知从 0 到  $2k$  的轨道个数为  $C_{k-1}$ ，因此有  $C_n = \sum_{k=0}^{n-1} C_{k-1} C_{n-k}$ ，

于是  $G(s) - 1 = sG^2(s)$ ，考虑合理解知  $G(s) = \frac{1 - \sqrt{1-4s}}{2s}$ ，展开可得  $C_n = \frac{(2n)!}{n!(n+1)!}$  (卡特兰数)。

定义 3.7 非负整值随机变量的母函数

$$G_X(s) = E[S^X] = \sum_{i=1}^{\infty} s^i P(X=i) = \sum_{i=1}^{\infty} f(i)s^i$$

\* 其收敛半径  $R \geq 1$ ，在收敛域内可微

\*  $G(0) = P(X=0), G(1) = 1, f(i) = \frac{G^{(i)}(0)}{i!}$

\* 只要系数非负， $G(1) = 1$ ，即可看作概率母函数

1. 二项分布  $B(n, p)$  母函数  $(ps + q)^n$

2. 几何分布  $P(X=i) = pq^{i-1}$  母函数  $\frac{ps}{1-qs}$

3. 泊松分布  $P(\lambda)$  母函数  $e^{\lambda(s-1)}$

定理 3.19 母函数与数字特征矩

1.  $E[X] = G'(1)$

2.  $E[x(x-1)\dots(x-k+1)] = G^{(k)}(1)$

3.  $\text{Var}(X) = G''(1) - G'(1)(1 - G'(1))$

此处  $G^{(k)}(1)$  指  $\lim_{x \rightarrow 1^-} G^{(k)}(x)$ ，由阿贝尔定理此定义合理。

证明：直接求导即可说明。

### 定理 3.20 随机变量卷积

设非负整值随机变量  $X_1, \dots, X_n$  互相独立,  $Y = \sum_{k=1}^n X_k$ , 则  $G_Y = \prod_{k=1}^n G_{X_k}$ 。

证明：利用卷积归纳即可。

### 定理 3.21 复合分布

设  $X_i$  独立同分布, 母函数  $G_X$ ,  $N$  与  $X_i$  独立, 母函数  $G_N$ ,  $Y = \sum_{k=1}^N X_k$  母函数为  $G_N(G_X)$ 。

证明：利用全概率公式分解计算。

### 定义 3.8 联合母函数

$X, Y$  联合母函数  $G(s, t) = E[s^x t^y] = \sum_{i,j} s^i t^j P(X=i, Y=j)$ 。

### 定理 3.22 $X, Y$ 独立等价于 $G(s, t) = G_X(s)G_Y(t)$

证明：比较系数。

例 3.18 掷三颗均匀骰子, 求点数和分布。

设每个骰子点数  $X_i$ , 和为  $Y$ , 则  $G_Y(s) = G_X^3(s) = \frac{s^3(1-s^6)^3}{6^3(1-s)^3}$ , 考虑每项系数即为分布。

\* 二项分布再生性: 独立变量  $X_1 \sim B(n_1, p), X_2 \sim B(n_2, p)$ , 考虑母函数可发现  $X_1 + X_2 \sim B(n_1 + n_2, p)$ 。

泊松分布也有再生性:  $X_1, X_2$  独立泊松分布  $P(\lambda_1), P(\lambda_2)$ , 其和分布为  $P(\lambda_1 + \lambda_2)$ 。

\* 离散随机变量的母函数是否可以定义为  $G(s) = \sum_i s^{x_i} P(X = x_i)$ ? 其他类型随机变量呢? (第五章内容)

## 四 连续型随机变量

### §4.1 独立性

$X$  连续型随机变量, 有密度函数  $f$ , 非负且在实轴上积分为 1, 分布函数  $F(x) = \int_{-\infty}^x f(u)du$ 。

\*  $P(X=x)=0, P(a < X < b) = \int_a^b f(u)du$

\* 均匀分布  $X \sim U[a, b]$

$f(x) = \frac{1}{b-a}, x \in [a, b]$

\* 指数分布  $X \sim \text{Exp}(\lambda)$

$f(x) = \lambda e^{-\lambda x}, F(x) = 1 - e^{-\lambda x}$

背景:  $P(t \leq X \leq t + \Delta t | X > t) = \lambda \Delta t$  微分方程 (如半衰期等)

也具有无记忆性

\* 正态分布  $X \sim N(\mu, \sigma^2)$

$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$

$\mu$  为对称轴且为最大值点

$\mu \pm \sigma$  为拐点

背景: 随机误差分布

Wigner 半圆律

$f(x) = \frac{1}{2\pi\sigma^2} \sqrt{4\sigma^2 - x^2}$

背景: 随机矩阵、自由概率论 (和正态分布同地位)

例 4.1 半圆律中  $P(X \in (0, \sigma))$

积分可得结果为  $\frac{1}{6} + \frac{\sqrt{3}}{4\pi}$

例 4.2  $X \sim N(0, 1)$ , 求  $Y = X^2$  密度函数

$P(Y \leq y) = P(-\sqrt{y} < X < \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$ , 求导得密度函数为  $\frac{e^{-y/2}}{\sqrt{2y\pi}}$ 。

\* 正态分布常用  $\phi(x)$  表示密度函数,  $\Phi(x) = \int_{-\infty}^x \phi(u) du$ ,  $N(0, 1)$  称标准正态分布。

\*  $X \sim U(0, 1)$ , 计算可得  $Y = \Phi^{-1}(X) \sim N(0, 1)$

定义 4.1 一般随机变量的独立性

$X_1, \dots, X_n$  满足  $P(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{k=1}^n P(X_k \leq x_k)$ , 则称随机变量相互独立。

定理 4.1 等价刻画  $X_1, \dots, X_n$  相互独立等价于  $\forall B_1, \dots, B_n \in B(\mathbb{R}), P(\forall i, X_i \in B_i) = \prod_{k=1}^n P(X_k \in B_k)$

(证明须更多测度论知识)

定理 4.2 设  $g_1, \dots, g_n$  均 Borel 可测,  $X_1, \dots, X_n$  独立, 则  $g_1(X_1), \dots, g_n(X_n)$  独立。

证明: 利用 Borel 集原像为 Borel 集可由上一定理说明。

定理 4.3 连续型随机变量的独立

$X_1, \dots, X_n$  密度函数  $f_1, \dots, f_n$ , 独立等价于  $f_1 \dots f_n$  为联合密度函数。

证明: 利用多重积分性质计算。

\* 卷积:  $X, Y$  独立时, 称  $Z = X + Y$  为其卷积,  $f_Z = f_X * f_Y$

定理 4.4  $(X, Y)$  密度函数为  $f(x, y)$ , 则  $f_{X+Y}(x) = \int_{\mathbb{R}} f(x, z-x) dx = \int_{\mathbb{R}} f(z-y, y) dy$

证明: 利用二重积分变量代换公式计算。

\*  $X, Y$  独立时,  $f(x, y) = f_X(x)f_Y(y)$ , 由此  $X + Y$  密度函数成为两函数卷积

例 4.3  $X, Y$  独立标准正态分布, 求  $X + Y$  分布函数。

利用定理计算积分得  $X + Y \sim N(0, 2)$ 。

## §4.2 期望

定义 4.2 连续型随机变量的期望

当  $\int_{\mathbb{R}} xf(x) dx$  绝对收敛, 定义其为  $X$  的数学期望  $E[X]$ 。

定理 4.5  $X$  有密度函数  $f$ , 期望存在, 则  $E[X] = \int_0^{\infty} (1 - F_X(x)) dx - \int_{-\infty}^0 F_X(x) dx$ 。

证明: 利用分部积分公式计算。

定理 4.6 复合的期望

$g$  为 Borel 可测函数,  $X$  与  $g(X)$  均为连续型随机变量, 则  $E[g(X)] = \int_{\mathbb{R}} g(x)f_X(x) dx$

证明: 利用上一定理由  $F$  推导计算。



**定理 4.7** 连续型随机向量情形

$g$  是二元 Borel 可测函数,  $X, Y$  联合分布  $f(x, y)$ ,  $g(X, Y)$  为连续型随机向量且期望存在, 则  $E[g(X, Y)] = \int_{\mathbb{R}^2} g(x, y)f(x, y)dxdy$ 。特别地, 当  $g = ax + by$  时代入可发现  $E[aX + bY] = aE[X] + bE[Y]$ 。

\* 可用于计算协方差

矩  $m_k = E[X^k]$ , 方差  $\text{Var}(X) = E[X^2] - E^2[X]$

协方差  $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$ , 相关系数  $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$

**定理 4.8** 柯西不等式

$(X, Y)$  连续型随机向量, 且  $E[X^2], E[Y^2]$  存在, 则  $(E[XY])^2 \leq E[X^2]E[Y^2]$

证明: 与离散情形相同构造。

\* 由此知  $|\rho| \leq 1$ , 当  $P(Y = aX) = 1$  时可取等。

**例 4.4** 正态分布

积分计算期望:  $\int_{\mathbb{R}} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx = \int_{\mathbb{R}} (x-\mu) \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx + \mu$   
 $= \int_{\mathbb{R}} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}x^2\right) dx + \mu = \mu$ 。  
 同样直接代入计算可知方差为  $\sigma^2$ 。

**例 4.5** 柯西分布

$f(x) = \frac{1}{\pi(1+x^2)}$ , 积分可知期望不存在。

**例 4.6** 二元正态分布

$f(x, y) = \frac{1}{\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right), \rho \in (-1, 1)$

计算可知  $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ , 因此  $X \sim N(0, 1)$ , 由对称性知  $Y$  亦如此,  $E[X] = E[Y] = 0$ 。

$\text{Cov}(X, Y) = E[XY] = \int_{\mathbb{R}^2} xyf(x, y)dxdy$  将  $xy$  写为  $x(y - \rho x) + \rho x^2$ , 可发现左侧项积分为 0, 考虑右侧按先  $y$  后  $x$  积分得  $\rho$ 。

此时  $\rho$  即为相关系数,  $\rho = 0 \Leftrightarrow X, Y$  独立。

条件期望: 直观上考虑  $P(Y \leq y | x < X \leq x + \Delta x), \Delta x \rightarrow 0$ , 可得  $\frac{\int_{-\infty}^y f(x, u)du}{f_X(x)}$

**定义 4.3** 设  $(X, Y)$  联合密度函数  $f(x, y)$ ,  $X$  分布为  $f_X(x)$ 

条件密度  $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$  关于  $y$  构成密度函数。

$F_{Y|X}(y|x) = \frac{\int_{-\infty}^y f(x, u)du}{f_X(x)}$

条件期望  $E[Y|X=x] = \int_{\mathbb{R}} yf_{Y|X}(y|x)dy$ , 由此有随机变量  $E[Y|X]$ 。

**定理 4.9** 期望形式的全概率公式

$E[E[Y|X]] = E[Y]$

**例 4.7** 二元正态分布的条件期望

关于  $y$  的分布为  $N(\rho x, 1 - \rho^2)$ , 由此  $E[Y|X] = \rho X$ 。

## §4.3 多元正态分布

一般分析结论: 随机向量  $(X_1, X_2)$  密度函数  $f(x_1, x_2)$ , 映射  $T: (X_1, X_2) \rightarrow (Y_1, Y_2)$ ,  $T$  为将  $D \subset \mathbb{R}^2$  映射到  $R \subset \mathbb{R}^2$  的一一映射,  $T: (x_1, x_2) \rightarrow (y_1(x_1, x_2), y_2(x_1, x_2))$ , 设其逆映射  $(x_1(y_1, y_2), x_2(y_1, y_2))$  有连续偏导数。则  $f_{Y_1, Y_2}(y_1, y_2) = f(x_1, x_2)|J|I_{T(D)}$ , 其中  $J$  是  $(x_1, x_2)$  的 Jacobi 行列式。

\* 证明: 利用变量替换, 考虑  $(Y_1, Y_2)$  取在 Borel 集  $(-\infty, y_1] \times (-\infty, y_2]$  中的概率。

(若在  $P(x_1, x_2 \in D_0) = 1, D_0 \subset D$  上一一映射, 结论仍成立)

例 4.8  $X, Y$  独立  $\sim N(0, 1)$ ,  $X = R \cos \Theta, Y = R \sin \Theta, R \geq 0, \Theta \in [0, 2\pi]$ , 求  $R, \Theta$  分布。

$f_{X, Y}(x, y) = \frac{1}{2\pi} e^{-x^2/2 - y^2/2}$ , 由此  $f_{R, \Theta}(r, \theta) = \frac{1}{2\pi} r e^{-r^2/2}, r \geq 0, \theta \in (0, 2\pi]$ , 有  $f_{\Theta}(\theta) = \frac{1}{2\pi}, f_R(r) = r e^{-r^2/2}$ 。

\*  $U_1, U_2$  独立  $\sim U(0, 1)$ , 则  $X = \sqrt{-2 \ln U_1} \cos(2\pi U_2), Y = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$  为独立标准正态分布。

一元正态分布  $N(\mu, \sigma^2)$ , 密度函数  $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$

二元正态分布  $f(x, y) = \frac{1}{\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right)$

一般情况:  $C_n e^{-Q(x_1, \dots, x_n)}$  二次型  $Q = \sum_{i,j} x_i x_j A_{ij}, A^T = A$ , 需加条件

定义 4.4 多元正态分布

$\vec{X} = (X_1, \dots, X_n)$  密度函数  $f(\vec{x}) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})\Sigma^{-1}(\vec{x} - \vec{\mu})^T\right)$ ,  $\Sigma = (\sigma_{ij})$  正定, 则记

$\vec{X} \sim N(\vec{\mu}, \Sigma)$

\*  $n = 2$  时可简化表达

定理 4.10 参数性质

设  $\vec{X} \sim N(\vec{\mu}, \Sigma)$ , 则

1.  $E[\vec{X}] = \vec{\mu}$

2.  $E[(\vec{X} - \vec{\mu})^T(\vec{X} - \vec{\mu})] = \Sigma$ , 即  $\sigma_{ij} = \text{Cov}(X_i, X_j)$

证明: 设  $\Sigma = B^T \Lambda B$  为正交相似对角化, 分析计算。

定理 4.11 线性变换下不变性

$\vec{X} \sim N(\vec{\mu}, \Sigma)$ ,  $D$  为  $n$  阶可逆方阵, 则  $\vec{X}D \sim N(\vec{\mu}D, D^T \Sigma D)$ 。

证明: 对分量分别计算可知结论。

定理 4.12  $\vec{X} \sim N(\vec{\mu}, \Sigma)$ ,  $\Sigma = \text{diag}(\Sigma_1, \Sigma_2)$ , 两分块均为方阵, 将向量与期望对应拆分为  $\vec{X}_1, \vec{X}_2$  与  $\vec{\mu}_1, \vec{\mu}_2$ , 则  $\vec{X}_1 \sim N(\vec{\mu}_1, \Sigma_1), \vec{X}_2 \sim N(\vec{\mu}_2, \Sigma_2)$ 。

证明: 分离变量得结果。

定理 4.13  $\vec{X} \sim N(\vec{\mu}, \Sigma)$ ,  $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$ , 将随机向量与期望对应拆分为  $\vec{X}_1, \vec{X}_2$  与  $\vec{\mu}_1, \vec{\mu}_2$ , 则  $\vec{X}_1 \sim N(\vec{\mu}_1, \Sigma_{11}), \vec{X}_2 \sim N(\vec{\mu}_2, \Sigma_{22})$ 。

证明: 对角化后利用分部积分计算。

定理 4.14 更广泛的线性变换下不变性

$\vec{X} \sim N(\vec{\mu}, \Sigma)$ ,  $D$  为  $n \times m$  阶列满秩方阵, 则  $\vec{X}D \sim N(\vec{\mu}D, D^T \Sigma D)$ 。

证明: 与之前类似, 拆分计算。

**定理 4.15 独立性**

$\Sigma = \text{diag}(\Sigma_1, \Sigma_2)$ , 各分量相互独立当且仅当协方差矩阵对角。

证明: 分离变量得结果。

\* 定义均值  $\bar{X} = \frac{X_1 + \cdots + X_n}{n}$ , 方差  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

**定义 4.5 卡方分布**

当密度函数  $f(x) = \frac{1}{2^{d/2}\Gamma(d/2)} x^{d/2-1} e^{-x/2}, x > 0$ , 称  $X$  服从  $d$  个自由度卡方分布, 记为  $X \sim \chi^2(d)$ 。

**定理 4.16 卡方分布性质**

$Y_1, \dots, Y_d$  独立同分布  $N(0, 1)$ , 则  $\sum_{i=1}^d Y_i^2 \sim \chi^2(d)$ 。

证明: 利用极坐标换元计算。

**定理 4.17 均值、方差性质**

设  $X_i$  独立同分布  $N(\mu, \sigma^2)$ , 则:

1.  $\bar{X} \sim N(\mu, \sigma^2/n)$
2.  $(n-1)/\sigma^2 S^2 \sim \chi^2(n-1)$
3.  $\bar{X}, S^2$  独立

复平面二维随机向量:  $Z = X + Yi$

$$E[Z] = E[X] + iE[Y]$$

复高斯分布:  $N_{\mathbb{C}}(\mu, \sigma^2), \mu \in \mathbb{C}, \sigma > 0$ , 联合密度  $f(z) = \frac{1}{\pi\sigma^2} \exp\left(-\frac{1}{\sigma^2}|z - \mu|^2\right)$ 。

结论:  $Z \sim N_{\mathbb{C}}(0, 1) \Rightarrow E[Z^k \bar{Z}^l] = \begin{cases} k! & k = l \\ 0 & k \neq l \end{cases}$

## 五 中心极限定理

### §5.1 一般随机变量的期望

#### 1. 记号准备

对随机变量  $X$  与分布函数  $F$ , 离散型/连续型具有分布列/分布函数  $f$ , 从而对  $xf(x)$  求和/积分可得期望。而由于  $dF$  分别为  $F(x) - F(x^-)/f(x)dx$ , 期望可统一写为  $E[X] = \int_{\mathbb{R}} x dF$ , 佚名统计学家公式也可写为  $E[g(X)] = \int_{\mathbb{R}} g(x) dF$ 。

#### 2. 抽象积分

对一般  $(\Omega, \mathcal{F}, P)$ , 随机变量  $X$  与分布函数  $F$ , 如何定义  $E[X]$ ?

STEP 1 对简单 (取有限个值) 随机变量

可记为  $X = \sum_{i=1}^n x_i I_{A_i}$ ,  $A_1, \dots, A_n$  为  $\Omega$  的划分, 则  $E[X] = \sum_{i=1}^n x_i P(A_i)$ 。

STEP 2 对非负随机变量

存在单调增的简单随机变量列, 收敛到此随机变量: 记  $X_n = nI_{A_n} + \sum_{j=1}^{n2^n} \frac{j-1}{2^n} I_{A_{nj}}$ , 其中  $A_{nj} = \{ \frac{j-1}{2^n} \leq X < \frac{j}{2^n} \}$ ,  $A_n = \{ X \geq n \}$ 。

再说明若简单随机变量序列  $X_n, Y_n$  均单调增收敛至  $X$ , 则期望的极限相同 (此处相同包含正无穷, 由此可由期望的极限定义  $X$  的期望)。

### STEP 3 对一般随机变量

将一般随机变量  $X$  写为  $X^+ - X^-$ ,  $X^+ = \max\{X, 0\}$ ,  $X^- = -\max\{-X, 0\}$ , 当  $E[X^+], E[X^-]$  至少一个有限时, 可定义  $E[X] = E[X^+] - E[X^-]$ 。特别地, 若两者都有限, 则称  $X$  的数学期望存在。

\* 统一记号为  $E[X] = \int_{\Omega} X dP$  或  $\int_{\Omega} X(\omega) P(d\omega)$

### 3 期望性质

非负性:  $X \geq 0 \Rightarrow E[X] \geq 0$  (由定义过程知成立)

规范性:  $c \in \mathbb{R} \Rightarrow E[c] = c$

线性性:  $E[aX + bY] = aE[X] + bE[Y]$

“连续性”:  $X_n$  趋向  $X$  (或偏移的概率为 0), 只要满足以下条件之一即有期望亦有极限:

1. 单调收敛:  $X_n$  单调
2. 控制收敛:  $|X_n| \leq Y, E[Y] < \infty$
3. 有界收敛:  $|X_n| \leq c, c \in \mathbb{R}$

### 4 Lebesgue-Stieltjes 积分

对随机变量  $X$  与分布函数  $F$ , 引入  $(\mathbb{R}, R(\mathbb{R}))$  上概率测度  $\mu_F((a, b]) = F(b) - F(a)$ , 则  $(\mathbb{R}, R(\mathbb{R}), \mu_F)$  构成概率空间。对 Borel 可测函数  $g$ , 有抽象积分  $\int g dF$ , 称为 Lebesgue-Stieltjes 积分。

有结论:  $E[g(X)] = \int g dF$ 。

证明: 回到三步的定义方式逐步证明。

\* 此结论对多元也成立

\* **Fatou 引理**:  $X_i$  非负随机变量, 则  $E[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} E[X_n]$

### 5 独立随机变量乘积期望与期望乘积相同

**定理 5.1**  $X, Y$  为独立随机变量, 且期望与乘积的均存在, 则  $E[XY] = E[X]E[Y]$

证明:

对简单随机变量: 直接拆分计算即可。

对非负随机变量: 注意到可取出两列递增的独立简单随机变量趋向  $X_n$  与  $Y_n$ , 由此得证。

对一般随机变量: 利用线性性拆分计算即可。

## §5.2 特征函数

\* 非负整值母函数定义:  $G_X(s) = \sum_{k=0}^{\infty} P(X = k) s^k = E[s^X]$

当  $s = e^t$ , 有矩母函数  $M_X(t) = E[e^{tX}]$

\* “好”的情形: 存在 0 的邻域使矩母函数存在

\* 不好的例子:  $f(x) = \frac{1}{\pi(1+x^2)}$

**定义 5.1**  $X, Y$  为  $(\Omega, \mathcal{F}, P)$  上随机变量, 称  $Z = X + Yi$  为复随机变量。

(1) 实质为二维随机向量

(2)  $Z_1, Z_2$  独立, 指  $(X_1, Y_1)$  与  $(X_2, Y_2)$  独立, 即  $P(X_1 \leq x_1, Y_1 \leq y_1, X_2 \leq x_2, Y_2 \leq y_2) = P(X_1 \leq x_1, Y_1 \leq y_1)P(X_2 \leq x_2, Y_2 \leq y_2)$ 。

(3)  $E[Z] = E[X] + iE[Y]$

(4)  $Z_i$  相互独立时,  $E[Z_1 \dots Z_n] = E[Z_1] \dots E[Z_n]$ 。

### 定义 5.2 特征函数

$\phi(t) = E[e^{itX}]$ , 有时用  $\phi_X(t)$  表示。

(1)  $\phi(t) = E[\cos(tX)] + iE[\sin(tX)]$

(2) 由于  $|e^{itx}| = 1$ ,  $\phi(t)$  总存在。

(3)  $\phi(t) = \int_{\mathbb{R}} e^{itx} dF(x)$ , 有分布函数时可写为  $\int_{\mathbb{R}} e^{itx} f(x) dx$ 。

### 定理 5.2 基本性质

1.  $\phi(0) = 1, |\phi(t)| \leq 1, \overline{\phi(t)} = \phi(-t)$

2.  $\phi$  在  $\mathbb{R}$  上一致连续。

3. 非负定性:  $t_i \in \mathbb{R}, z_i \in \mathbb{C}$ , 有  $\sum_{j,k=1}^n \phi(t_j - t_k) z_j \overline{z_k} \geq 0$ 。

证明:

2.  $|\phi(t+h) - \phi(t)| \leq \int_{\mathbb{R}} |e^{itx}(e^{ihx} - 1)| dF \leq \int_{\mathbb{R}} |e^{ihx} - 1| dF$ , 有界收敛定理可知一致趋于 0。

3. 原式  $= E\left[\left|\sum_j z_j e^{it_j x}\right|^2\right] \geq 0$ 。

\* 满足定理 5.2 三条性质的函数必为某随机变量的特征函数

**定理 5.3**  $E[|X|^k] < \infty$ , 则  $\forall j < k, \phi^{(j)}(0) = i^j E[X^j]$ , 进而  $\phi(t) = \sum_{j=0}^k \frac{(it)^j}{j!} E[X^j] + o(t^k)$ 。

证明: 由题 6.5.4 知  $E[|X|^j] < \infty$ , 由此积分与求导可交换, 再由求导结果可知成立。

### 定理 5.4 两变量特征函数关系

1.  $Y = aX + b$  时  $\phi_Y(t) = e^{ibt} \phi_X(at)$ 。

2.  $X, Y$  独立时  $\phi_{X+Y}(t) = \phi_X(t) \phi_Y(t)$ 。

证明: 直接计算即可。

### 定义 5.3 多元特征函数

$\vec{X} = (X_1, \dots, X_n)$  的特征函数为  $\phi_{\vec{X}}(\vec{t}) = E[e^{i \sum_j t_j X_j}]$ 。

### 定理 5.5 独立性

$X, Y$  独立当且仅当  $\phi_{X,Y}(s, t) = \phi_X(s) \phi_Y(t)$ 。

证明: 左推右可直接计算, 右推左需要反转公式 (见下节)。

### 例 5.1 Bernoulli 分布

$\phi(t) = pe^{it} + q$

由此亦可知二项分布母函数为  $(pe^{it} + q)^n$

\* 对非负整值随机变量, 母函数  $G$ , 则  $G(e^{it})$  即为特征函数。

**例 5.2** 指数分布

$$f(x) = \lambda e^{-\lambda x}, x > 0$$

$$\phi(t) = \frac{\lambda}{\lambda - it}$$

证明：可分别计算实部虚部积分，亦可通过复分析直接计算。

**例 5.3** 标准正态分布  $N(0, 1)$ 

$$\phi(t) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx - x^2/2} dx = e^{-t^2/2}$$

证明：“物理方法”假设  $it$  为实数，再解析延拓；“数学方法”计算导数说明。

\*  $N(\mu, \sigma^2)$  的分布函数为  $e^{i\mu t - \sigma^2 t^2/2}$

**例 5.4** 多元正态分布  $N(\vec{\mu}, \Sigma)$ 

$$\phi(\vec{t}) = \exp\left(\frac{i\vec{\mu}\vec{t}^T - \vec{t}^T \Sigma \vec{t}^T}{2}\right)$$

证明：设  $Y = \vec{X} \cdot \vec{t}^T$ ，将其化为一元正态分布的情况。

**例 5.5** 均匀分布  $U(-1, 1)$ 

$$\phi(t) = \frac{\sin t}{t}$$

**§5.3 反转与连续性定理****定理 5.6** 反转公式

$$-\infty < a < b < \infty, \frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2} = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{2\pi it} \phi(t) dt$$

理解：类似傅里叶反变换

证明：记极限中的积分为  $I_T$ ， $I_T = \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{2\pi it} \int_{\mathbb{R}} e^{itx} dF dt$ ，由 **Fubini 定理** 积分符号可交换，由积分区域对称可转化为  $\int_{\mathbb{R}} g_T(x) dF$ ， $g_T(x) = \frac{1}{\pi} \int_0^T \left( \frac{\sin t(x-a)}{t} - \frac{\sin t(x-b)}{t} \right) dt$ 。由于  $\int_0^{+\infty} \frac{\sin tx}{\pi t} = \begin{cases} 1/2 & x > 0 \\ 0 & x = 0 \\ -1/2 & x < 0 \end{cases}$ ， $g_T(x)$  有界，由控制收敛定理其极限为  $\begin{cases} 1 & x \in (a, b) \\ 1/2 & x = a, b \\ 0 & \text{其他} \end{cases}$ ，因此结果为  $P(X \in (a, b)) + \frac{P(X=a) + P(X=b)}{2}$ ，即为左侧。

\* 推论：特征函数相同即可知同分布

证明：记  $C_F$  为  $F$  连续点， $\mathbb{R} \setminus C_F$  至多可数。让  $a, b \in C_F, a \rightarrow -\infty$ ，可唯一确定  $F(b)$ ，由此连续点已唯一确定。再用连续点从右侧逼近可唯一确定不连续点处。

**定理 5.7** 假设随机向量对任何长方体，落入其表面概率为 0，则有：

$$P(a_j < X_j \leq b_j, j = 1, \dots, n) = \lim_{T_i \rightarrow \infty} \int_{-T_n}^{T_n} \cdots \int_{-T_1}^{T_1} \prod_{j=1}^n \frac{e^{-ia_j t} - e^{-ib_j t}}{2\pi i t_j} \phi(t_1, \dots, t_n) dt_1 \cdots dt_n$$

\* 由此即可说明特征函数可分离变量时随机变量独立

**例 5.6** 求  $\cos t$  对应的分布函数。

可构造出  $P(X=1) = P(X=-1) = \frac{1}{2}$ ，由此分布函数即为结果。

\* 对随机变量  $X_n$ ，分布函数  $F_n$ ，特征函数  $\phi_n$ ， $F_n, \phi_n$  收敛性关系？

例 5.7  $X_n = \frac{1}{n}$ , 分布函数的极限为  $\begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$ , 不满足右连续性。

定义 5.4 分布函数的收敛

$F, F_n$  为分布函数, 称  $F_n$  弱收敛至  $F$ , 若对  $F$  的任意连续点  $x$ ,  $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ , 记作  $F_n \xrightarrow{W} F$ 。

定理 5.8 Lévy-Cramér 连续性定理

假设  $F_n$  为分布函数, 对应特征函数  $\phi_n$

1. 若  $F_n \xrightarrow{W} F$ ,  $F$  为分布函数, 对应特征函数  $\phi$ , 则  $\phi_n$  内闭一致收敛到  $\phi$ 。
2. 若  $\phi_n$  逐点收敛到  $\phi$ ,  $\phi$  在  $t=0$  处连续, 则  $\phi(t)$  为特征函数, 其对应分布函数  $F$ , 且  $F_n \xrightarrow{W} F$ 。

例 5.8  $X \sim U(-n, n)$ , 则  $\phi_n(t) = \frac{\sin nt}{nt}$ , 特征函数极限为  $\begin{cases} 0 & t \neq 0 \\ 1 & t = 0 \end{cases}$ , 不满足连续性。

## §5.4 极限定理

1. 问题: 研究  $T_n = \frac{1}{B_n} \sum_{i=1}^n (X_i - a_i)$  的极限性质

\*  $X_k$  性质-独立同分布

\*  $a_k = E[X_k], B_n = c\sqrt{n}$

\* 研究不同收敛意义下极限

2. 大数定律 (LLN)、中心极限定理 (CLT)

定义 5.5 弱收敛

若  $F_{X_n} \xrightarrow{W} F_X$ , 则称  $X_n$  依分布收敛 (弱收敛) 到  $X$ , 记为  $X_n \xrightarrow{D} X$ 。

定理 5.9 大数定律

$X_i$  独立同分布, 期望  $\mu = E[X_i]$  存在, 令  $S_n = \sum_{k=1}^n X_k$ , 则  $\frac{S_n}{n} \xrightarrow{D} \mu$ , 即  $\frac{S_n}{n} - \mu \xrightarrow{D} 0$ 。

证明: 运用连续性定理, 由  $\phi'_X(0) = \mu i$  将  $X_i$  的分布函数在 0 处展开一次项即可计算得结果。

\*  $\frac{S_n}{n} - \mu$  的无穷小阶数可推测为  $\frac{1}{\sqrt{n}}$ , 这是由于  $\text{Var}(S_n) = n \text{Var}(X_1)$ , 具体定理为:

定理 5.10 中心极限定理

$X_i$  独立同分布, 期望  $\mu = E[X_i]$ , 方差  $\sigma^2 = \text{Var}(X_i), \sigma > 0$  存在, 则  $\frac{S_n - n\mu}{\sqrt{n}\sigma^2} \xrightarrow{D} N(0, 1)$ 。

证明: 通过平移放缩可不妨设  $\mu = 0, \sigma = 1$ , 再对  $\frac{S_n}{\sqrt{n}}$  展开估算。

例 5.9 各次测量值独立同分布, 方差为 4, 欲以 95% 把握保证测量精度达  $\pm 0.5$ , 求最低测量次数。

$Z_n = \frac{S_n - n\mu}{2\sqrt{n}} \xrightarrow{D} N(0, 1)$ ,  $P\left(\frac{S_n}{n} - \mu\right) \leq 0.5 = P\left(|Z_n| \leq \frac{\sqrt{n}}{4}\right)$ , 将  $Z_n$  视为正态分布, 查表得至少需要  $n = 62$ 。

3. Lindeberg 条件 (处理独立但未必同分布)

设  $a_k = E[X_k], b_k^2 = \text{Var}(X_k), B_n^2 = \sum_{k=1}^n b_k^2$ ,  $F_k$  为  $X_k$  分布函数。

L 条件:  $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} (x-a_k)^2 dF_k = 0$

**定理 5.11 Lindeberg - Feller CLT**

$X_i$  相互独立, 满足 L 条件, 则  $\frac{\sum_{k=1}^n (X_k - a_k)}{B_n} \xrightarrow{D} N(0, 1)$ , 且  $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

特别地,  $X_i$  相互独立,  $a_i = 0$ ,  $E[|X_i|^3] < \infty$ , 且  $\frac{1}{B_n^3} \sum_{k=1}^n E[|X_k|^3] \rightarrow 0$ , 则  $\frac{\sum_{k=1}^n X_k}{B_n} \xrightarrow{D} N(0, 1)$ 。

\* 由  $\int_{|x| > \varepsilon B_n} x^2 dF_k \leq \frac{1}{\varepsilon B_n} \int_{|x| > \varepsilon B_n} |x|^3 dF_k$  即可验证特殊情况。

注:

(1) L 条件的概率意义:

$$\sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} \frac{(x-a_k)^2}{B_n^2} dF_k \geq \varepsilon^2 \sum_{k=1}^n P\left(\frac{|X_k - a_k|}{B_n} > \varepsilon\right) \geq \varepsilon^2 P\left(\bigcup_{k=1}^n \left\{\frac{|X_k - a_k|}{B_n} > \varepsilon\right\}\right) \\ = \varepsilon^2 P\left(\frac{\max_k |X_k - a_k|}{B_n} > \varepsilon\right), \text{ 由此 L 条件可推出 } P\left(\frac{\max_k |X_k - a_k|}{B_n} > \varepsilon\right) \rightarrow 0.$$

(2)  $X_i$  相互独立时, L 条件增加  $B_n \rightarrow \infty$ ,  $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$  (Feller 条件) 即为 CLT 的必要条件。

(3) Lyapunov 条件:  $\exists \delta > 0, E[|X_i - a_i|^{2+\delta}] < \infty$ , 且  $\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E[|X_k - a_k|^{2+\delta}] \rightarrow 0$

类似特殊情况的推导知 Lyapunov 条件可推出 L 条件, 从而推出 CLT。

(4) 利用  $b_k^2 = \int_{\mathbb{R}} (x - a_k)^2 dF_k$  可拆分为两段, 放缩知  $\frac{b_k^2}{B_n^2}$  在极限时一致  $\leq \varepsilon^2$ , 从而  $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

**4. 局部极限定理 (LLT)**

\* 二项分布的正态逼近

取  $X_i$  独立同分布  $B(1, p)$ , 由再生性知  $S_n \sim B(n, p)$ , 由此可进行估计:

**定理 5.12 二项分布的局部极限定理**

$p \in (0, 1), q = 1 - p, x_k = \frac{k - np}{\sqrt{npq}}$ , 对  $|x_k| \leq A$ ,  $n \rightarrow \infty$  时一致地有  $C_n^k p^k q^{n-k} \sim \frac{1}{\sqrt{2\pi npq}} e^{-x_k^2/2}$ 。

证明: 利用 Stirling 公式估算系数。

**定理 5.13 积分形式 LLT**

$S_n \sim B(n, p)$ , 则  $P\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) \rightarrow \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx$

证明: 取上一定理中  $x_k$ , 有:

左 =  $\sum_{k: x_k \in (a, b]} C_n^k p^k q^{n-k} \sim \sum_{k: x_k \in (a, b]} \frac{e^{-x_k^2/2}}{\sqrt{2\pi npq}} = \sum_{k: x_k \in (a, b]} \frac{e^{-x_k^2/2}}{\sqrt{2\pi}} (x_{k+1} - x_k) \rightarrow$  右, 最后一步是由于黎曼和极限为积分。

\*  $n$  固定时,  $x_k$  与  $k$  一一对应, 形成等距分划

**5. 矩方法**

$$\gamma_k = \int_{\mathbb{R}} x^k \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \begin{cases} 0 & 2 \nmid k \\ (k-1)!! & 2 \mid k \end{cases}, \text{ 可看作 } 1, 2, \dots, k \text{ 两两配对的方式数。}$$

**定理 5.14**  $X_i$  独立, 且期望均为 0, 方差均为 1,  $\forall m \geq 3, C_m = \sup_k E[|X_k|^m] < \infty$  (一致有界高阶矩), 则

$S_n = \sum_{i=1}^n X_i$  有  $E\left[\left(\frac{S_n}{\sqrt{n}}\right)^k\right] \rightarrow \gamma_k$ , 进而  $\frac{S_n}{\sqrt{n}} \xrightarrow{D} N(0, 1)$ 。



证明:  $E\left[\left(\frac{S_n}{\sqrt{n}}\right)^k\right] = n^{-k/2} \sum_{i_1, \dots, i_k} E[X_{i_1} \dots X_{i_k}]$ , 其中非零项每个随机变量次数必至少为 2。由于高阶矩一致有界, 若选出的项小于  $k/2$  个, 会在极限中趋于 0, 由此只有  $k = 2m$  时可两两配对  $i_1, \dots, i_{2m}$  得出项, 再由每种配对方式对应极限为 1 可算出结果。

\* 由矩的极限推出依分布收敛:

**定理 5.15** 矩收敛定理

条件:

1.  $k \in \mathbb{N}, \gamma_{k,n} = \int x^k dF_n$  存在

2.  $\forall k, \lim_{n \rightarrow \infty} \gamma_{k,n} = \gamma_k$

3.  $\gamma_k = \int x^k dF$ , 且满足 Carleman 条件  $\sum_{k=1}^{\infty} (\gamma_{2k})^{-1/(2k)} = \infty$

则  $F_n \xrightarrow{W} F$ 。

## 六 几种收敛

### §6.1 四种收敛方式

**定义 6.1** 假设  $X, X_n$  为  $\{\Omega, \mathcal{F}, P\}$  上的随机变量, 则:

1. 几乎处处收敛 (以概率 1 收敛):

$$P(\{\omega \in \Omega : X_n(\omega) - X(\omega) \rightarrow 0\}) = 1,$$

记作  $X_n \xrightarrow{a.s.} X$ 。

2.  $r$  阶收敛:

$$r \in \mathbb{N}^*, \forall n, E[|X_n|^r] < \infty, \text{ 且 } E[|X_n - X|^r] \rightarrow 0,$$

记作  $X_n \xrightarrow{r} X$ 。 $r = 1$  时称平均收敛,  $r = 2$  时称均方收敛。

3. 依概率收敛:

$$\forall \varepsilon > 0, P(|X_n - X| > \varepsilon) \rightarrow 0,$$

记作  $X_n \xrightarrow{P} X$ 。

4. 依分布收敛:

$$F_X \text{ 的连续点处 } P(X_n \leq x) \rightarrow P(X \leq x),$$

记作  $X_n \xrightarrow{D} X$ 。

\* 依分布收敛与样本空间选择无关, 具有特殊性

**定理 6.1** 四种收敛的关系

$$X_n \xrightarrow{a.s.} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$$

$$r > s, X_n \xrightarrow{r} X \Rightarrow X_n \xrightarrow{s} X \Rightarrow X_n \xrightarrow{P} X$$

且反方向均无法推出, 由此强弱有严格性。

定理证明拆分为以下:

1.  $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$

$F_n(x) = P(X_n \leq x, X \leq x + \varepsilon) + P(X_n \leq x, X > x + \varepsilon) \leq F(x + \varepsilon) + P(|X - X_n| > \varepsilon)$ , 同理  $F(x - \varepsilon) \leq F_n(x) + P(|X - X_n| > \varepsilon)$ , 连续点处考虑  $F_n(x)$  上下极限可知结果。

例 6.1  $X_n \xrightarrow{D} X \not\Rightarrow X_n \xrightarrow{P} X$

$P(X=0) = P(X=1) = \frac{1}{2}, Y=1-X, X_n=X$ , 则  $X_n \xrightarrow{D} Y$ , 但其他三种收敛均不成立。

2.  $r > s, X_n \xrightarrow{r} X \Rightarrow X_n \xrightarrow{s} X$

利用问题 14.4.28(可由 **Hölder 不等式** 证明) 有  $E[|X_n - X|^s]^{1/s} \leq E[|X_n - X|^r]^{1/r}$ , 由此得结论。

3.  $X_n \xrightarrow{1} X \Rightarrow X_n \xrightarrow{P} X$

考虑概率测度在  $|X| \geq a$  部分的积分得 **Markov 不等式**:  $a > 0, P(|X| > a) \leq \frac{E[|X|]}{a}$ , 由此取  $a = \varepsilon$  知结论。

**\*Chebyshev 不等式**:  $a > 0, P(|X - E[X]| > a) \leq \frac{\text{Var}(X)}{a^2}$

例 6.2  $X_n \xrightarrow{P} X \not\Rightarrow X_n \xrightarrow{r} X$

$\Omega = (0, 1], P$  为 Lebesgue 测度,  $X_n(\omega) = \begin{cases} n^{1/r} & \omega \in \left(0, \frac{1}{n}\right] \\ 0 & \omega \in \left(\frac{1}{n}, 1\right] \end{cases}, X=0$ , 计算可验证依概率收敛但不  $r$  阶收敛。

4.  $X_n \xrightarrow{a.s.} X \Rightarrow X_n \xrightarrow{P} X$

分析得  $\{\omega \in \Omega : X_n(\omega) - X(\omega) \rightarrow 0\} = \bigcap_{k=1}^{\infty} \bigcup_{m=1}^{\infty} \bigcap_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| \leq \frac{1}{k}\}$ , 由此

知  $X_n \xrightarrow{a.s.} X \Leftrightarrow P\left(\bigcup_{k=1}^{\infty} \bigcap_{m=1}^{\infty} \bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \frac{1}{k}\}\right) = 0$ , 类似分析得其等价于

$\forall \varepsilon > 0, \lim_{m \rightarrow \infty} P\left(\bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) = 0$ , 由此得结论。

例 6.3  $X_n \xrightarrow{r} X \not\Rightarrow X_n \xrightarrow{a.s.} X$ , 由此  $X_n \xrightarrow{P} X \not\Rightarrow X_n \xrightarrow{a.s.} X$

$X_i$  相互独立,  $X_n \sim B(1, \frac{1}{n})$ , 可验证任意  $r$  阶均收敛, 但  $P\left(\bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) = 1$ , 故不几乎处处收敛。

**定理 6.2** 反向的成立条件

1. 若  $X_n \xrightarrow{D} c \in \mathbb{R}$ , 则  $X_n \xrightarrow{P} c$ 。

2. 若  $\exists k, P(|X_n| \leq k) = 1, X_n \xrightarrow{P} X$ , 则  $X_n \xrightarrow{r} X$ 。

3. 若  $\forall \varepsilon > 0, \sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty$ , 则  $X_n \xrightarrow{a.s.} X$ 。

证明:

1. 利用  $P(|X_n - c| > \varepsilon) = P(X_n > c + \varepsilon) + P(X_n < c - \varepsilon)$ , 利用分布函数估计知结果。

2. 先拆分  $X$  为  $|X - X_n| + |X_n|$  估计出  $X$  有同样的界, 再将差的期望拆分为  $|X_n - X| \leq \varepsilon$  与  $|X_n - X| > \varepsilon$  的部分可知期望的极限。

3. 利用并的概率小于等于概率的和直接估算。

**定理 6.3** 弱大数律

$X_i$  独立同分布, 期望  $\mu = E[X_i]$  存在, 令  $S_n = \sum_{k=1}^n X_k$ , 则  $\frac{S_n}{n} \xrightarrow{P} \mu$ 。

证明: 由大数定律与收敛于常随机变量得出。

**定理 6.4** Skorokhod 表示定理

设  $X_n \xrightarrow{D} X$ , 则存在  $(\Omega, \mathcal{F}, P)$ , 其上的  $Y_n, Y$  满足  $Y_n$  与  $X_n$ ,  $Y$  与  $X$  同分布,  $Y_n \xrightarrow{a.s.} Y$ 。

**定理 6.5** 弱收敛性质

$X_n \xrightarrow{D} X \Leftrightarrow \forall g \in C_b(\mathbb{R})$  (有界连续函数),  $E[g(X_n)] \rightarrow E[g(X)]$ 。

证明: 左推右由表示定理将  $X_n, X$  替换为  $Y_n, Y$  利用控制收敛定理可说明  $E[g(Y_n)] \rightarrow E[g(Y)]$ ; 右推左利用  $P(X_n \leq x) = E[I_{(-\infty, x]}(X_n)]$ , 以有界连续函数逼近知结论。

**§6.2 重要结论****1. 不等式**

\* 记  $\|X\|_p = E[|X|^p]^{1/p}, p \geq 1$

Hölder 不等式:  $\frac{1}{p} + \frac{1}{q} = 1, E[|XY|] \leq \|X\|_p \|Y\|_q$

Minkowski 不等式:  $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$

Markov 不等式:  $a > 0, aP(|X| > a) \leq E[|X|]$

Chebyshev 不等式:  $a > 0, a^2 P(|X - E[X]| > a) \leq \text{Var}(X)$

**例 6.4**  $\exists r > 0, E[|X|^r] = 0 \Rightarrow P(X = 0) = 1$

由 Markov 不等式,  $\forall \varepsilon, P(|X| \geq \varepsilon) \leq \frac{E[|X|^r]}{\varepsilon^r} = 0$ , 由此  $P(|X| < \varepsilon) = 1 \Rightarrow P(|X| \leq 2\varepsilon) = 1$ , 利用右连续性有结论。

**2. 收敛**

**定理 6.6** 记  $\square$  为 *a.s.* 或 *r* 或 *P*, 有:

1.  $X_n \xrightarrow{\square} X, X_n \xrightarrow{\square} Y \Rightarrow P(X = Y) = 1$

2.  $X_n \xrightarrow{\square} X, Y_n \xrightarrow{\square} Y \Rightarrow X_n + Y_n \xrightarrow{\square} X + Y$

3. 前两条对依分布收敛一般不成立, 但 1. 可以改为  $X, Y$  同分布

证明: 利用拆分与不等式放缩可验证成立, 对依分布收敛, 取  $P(X = 1) = P(X = -1) = \frac{1}{2}, Y_n = X_n = Y = -X$  即为前两条的反例, 利用连续点处相等与单调右连续可知同分布。

**3. Borel - Cantelli 引理**

事件列的上下极限:

$A_n$  的上限事件:  $\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m$  ( $A_n$  中发生无穷多次的样本点),

$A_n$  的下限事件:  $\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{m=n}^{\infty} A_m$  ( $A_n$  中至多有限多次不发生的样本点)

\*  $A_n$  的上限事件记为  $\{A_n \text{ i.o.}\}$ 。

**定理 6.7** Borel - Cantelli 引理

1.  $\sum_{n=1}^{\infty} P(A_n) < \infty \Rightarrow P(A_n \text{ i.o.}) = 0$

2.  $\sum_{n=1}^{\infty} P(A_n) = \infty, A_i \text{ 独立} \Rightarrow P(A_n \text{ i.o.}) = 1$

证明: 利用交、并、独立与概率的连续性放缩。

\* 由此可发现, 若  $A_i$  独立,  $P(A_n \text{ i.o.})$  只能为 0 或 1 (零一律)。

例 6.5  $X_i \sim \text{Exp}(1)$  独立同分布, 则  $P\left(\limsup_{n \rightarrow \infty} \frac{X_n}{\ln n} = 1\right) = 1$ 。

令  $A_n = \left\{ \frac{X_n}{\ln n} \geq 1 + a \right\}$ , 则  $P(A_n) = \frac{1}{n^{1+a}}$  且相互独立。

可发现  $a \in (-1, 0]$  时  $P(A_n \text{ i.o.}) = 1$  ( $A_n$  几乎处处发生无穷多次),  $a > 0$  时  $P(A_n \text{ i.o.}) = 0$  ( $A_n$  几乎处处只发生有限多次), 由此知结论。

### §6.3 强大数律

弱大数律:  $X_i$  独立同分布, 期望  $\mu = E[X_i]$  存在, 令  $S_n = \sum_{k=1}^n X_k$ , 则  $\frac{S_n}{n} \xrightarrow{P} \mu$ 。

#### 定理 6.8 强大数律

$X_i$  独立同分布, 期望  $\mu = E[X_i]$  存在,  $E[X_i^2]$  存在, 令  $S_n = \sum_{k=1}^n X_k$ , 则  $\frac{S_n}{n} \xrightarrow{2} \mu, \frac{S_n}{n} \xrightarrow{a.s.} \mu$ 。

证明: 对均方收敛, 可由独立性直接计算  $E\left[\left(\frac{S_n}{n} - \mu\right)^2\right] = \frac{\text{Var}(X_1)}{n} \rightarrow 0$ 。

对几乎处处收敛, 先找几乎处处收敛的子列, 再证明对非负的  $X_k$  成立, 最后推至一般。

#### 定理 6.9 柯尔莫哥洛夫强大数律

$X_i$  独立同分布, 则  $\frac{X_1 + \cdots + X_n}{n} \xrightarrow{a.s.} \mu \Leftrightarrow E[|X_1|] \text{ 存在且 } E[X_1] = \mu$ 。

左推右证明: 由于可拆分为两部分, 不妨设随机变量均非负。

STEP 1 截尾: 取  $Y_n = X_n I_{X_n < n}$ , 拆分估计可知  $\sum_{n=1}^{\infty} P(X_n \neq Y_n) = \sum_{n=1}^{\infty} P(X_n \geq n) < \infty$ , 因此  $P(X_n \neq Y_n \text{ i.o.}) = 0$ , 因此  $\frac{\sum_{k=1}^n (X_k - Y_k)}{n} \xrightarrow{a.s.} 0$ , 由此只需证结论对各阶矩存在的  $Y_n$  成立。

STEP 2 几乎处处收敛子列: 对  $\alpha > 1$ , 令  $\beta_k = \lceil \alpha^k \rceil$ , 则  $\frac{\beta_{k+1}}{\beta_k} \rightarrow \alpha$ , 且存在  $A$  使  $\forall m, \sum_{k=m}^{\infty} \frac{1}{\beta_k^2} \leq \frac{A}{\beta_m^2}$ 。  
记  $S'_n = \sum_{i=1}^n Y_i$ , 利用二阶矩估计知  $\sum_{n=1}^{\infty} P\left(\left|\frac{S'_{\beta_n} - E[S'_{\beta_n}]}{\beta_n}\right| > \varepsilon\right) < \infty$ , 由此  $\left|\frac{S'_{\beta_n} - E[S'_{\beta_n}]}{\beta_n}\right| > \varepsilon \xrightarrow{a.s.} 0$ ,  
进而  $\frac{S'_{\beta_n}}{\beta_n} \xrightarrow{a.s.} \mu$ 。

STEP 3 收敛: 由于  $S'_n$  单调增,  $\beta_m \leq n < \beta_{m+1}$  有  $\frac{\beta_m}{n} \cdot \frac{S'_{\beta_m}}{\beta_m} < \frac{S'_n}{n} < \frac{\beta_{m+1}}{n} \cdot \frac{S'_{\beta_{m+1}}}{\beta_{m+1}}$ , 取上下极限可估计得结论成立

\* 推论 (Borel 强大数律): 试验中事件  $A$  发生概率  $p$ ,  $S_n$  为  $n$  次独立重复试验中  $A$  发生次数, 则  $\frac{S_n}{n} \xrightarrow{a.s.} p$ 。

#### 定理 6.10 重对数律

$X_i$  独立同分布, 期望 0, 方差 1, 则:

$$P\left(\limsup_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \ln \ln n}} = 1\right) = 1$$

$$P\left(\liminf_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \ln \ln n}} = -1\right) = 1$$

\* 意味着 CLK 不能加强到更强的收敛

## 七 概率论外篇

### §7.1 信息熵

记事件  $E$  发生概率  $p = P(E)$ , 定义“惊奇程度”  $S(p)$ , 基本要求:  $S(1) = 0$ 、 $S(p)$  严格单调减、关于  $p$  连续、 $S(pq) = S(p) + S(q)$  (直观理解: 独立事件引起惊奇程度为分别发生之和)。这些要求可确定:

**定理 7.1**  $S(p) = -c \ln p, c > 0$ 。

证明：先考虑  $p_0^{m/n}$ ，再由连续推到一切  $p$ 。

**定义 7.1** Shannon 熵

离散型随机变量  $X$ ，取不同点概率为  $p_1, \dots, p_n, \dots$ ，定义  $H(X) = -\sum_k p_k \ln p_k$ 。

联合熵： $H(x, y) = -\sum_{i,j} P(x_i, y_j) \ln P(x_i, y_j)$ 。

相对熵： $H_Y(X) = \sum_j H_{Y=y_j}(X) P_Y(y_j)$ ，其中  $H_{Y=y_j}(X) = -\sum_i P(x_i|y_j) \ln P(x_i|y_j)$ 。

注： $H_Y(X) = -\sum_{i,j} P(x_i, y_j) \ln \frac{P(x_i, y_j)}{P_Y(y_j)}$

**定理 7.2**  $H(X, Y) = H(Y) + H_Y(X)$

证明：直接计算知结论。

**定理 7.3**  $H_Y(X) - H(X) \leq 0$

证明：由  $\ln x \leq x - 1$  估计知结论。

\* 由凸性可知  $P(X = x_i) = p_i, i = 1, 2, \dots, n$ ， $p_1 = \dots = p_n = \frac{1}{n}$  时  $H(X) = \ln n$  最大，即熵可代表不确定程度的大小。

**定义 7.2** 连续型随机变量的熵  $X$  连续，密度函数  $f(x)$ ，则  $H(X) = -\int_{\mathbb{R}} f(x) \ln f(x) dx$ 。

联合熵： $H(X, Y) = -\int_{\mathbb{R}^2} f(x, y) \ln f(x, y) dx dy$ 。

\***Gibbs 不等式** (利用分析知识可证明)： $u - u \ln u \leq v - u \ln v$ ，积分得  $\int_{\mathbb{R}} f(1 - \ln f) dx \leq \int_{\mathbb{R}} g(1 - \ln g) dx$ ，

再利用密度函数在实轴积分为 1 知  $\int_{\mathbb{R}} -f \ln f dx \leq \int_{\mathbb{R}} -f \ln g dx$ 。

**定理 7.4** 熵最大的条件

令  $D = \{x \in \mathbb{R} : f(x) \neq 0\}$ ，则：

1.  $D = \mathbb{R}, E[X] = 0, \text{Var}(X) = 1$  时，正态分布  $N(0, 1)$  熵最大，为  $\ln \sqrt{2\pi e}$ 。
2.  $D = (0, \infty), E[X] = \frac{1}{\lambda}$  时，指数分布  $\text{Exp}(\lambda)$  熵最大，为  $\ln \frac{e}{\lambda}$ 。
3.  $D = [0, a]$  时，均匀分布  $U(0, a)$  熵最大，为  $\ln a$ 。

证明：分别取  $g$  为三种分布的密度函数，利用 Gibbs 不等式估算即可。

\***Boltzmann 熵**： $S = k \ln \Omega$ ， $k = k_B$  为玻尔兹曼常数， $\Omega$  为微观状态数 (类似离散型均匀分布时的情况)。

## §7.2 Linderberg 替换理论

\*L 条件形式 CLK:

设  $a_k = E[X_k], b_k^2 = \text{Var}(X_k), B_n^2 = \sum_{k=1}^n b_k^2$ ， $F_k$  为  $X_k$  分布函数。

$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} (x-a_k)^2 dF_k = 0$ ，则  $\frac{\sum_{k=1}^n (X_k - a_k)}{B_n} \xrightarrow{D} N(0, 1)$ ，且  $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

**定理 7.5**  $X_n \xrightarrow{D} X$  等价于下列条件之一:

1.  $\forall g \in C_b(\mathbb{R})$  (有界连续函数),  $E[g(X_n)] \rightarrow E[g(X)]$ 。
2. 任意有界一致连续  $g$ ,  $E[g(X_n)] \rightarrow E[g(X)]$ 。
3. 给定  $m \in \mathbb{N}$ ,  $\forall g \in C_b(\mathbb{R}), g', g'', \dots, g^{(m)} \in C_b(\mathbb{R})$ ,  $E[g(X_n)] \rightarrow E[g(X)]$ 。
4.  $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$  (逐点收敛)。

Linderberg 思想: 取至三阶导均有界连续的  $g$ , 独立随机变量列  $Y_n \sim N(0, b_n^2)$ , 与  $X_n$  亦独立。

定义  $\zeta_{nk} = \sum_{1 \leq i < k} X_k + \sum_{k < i \leq n} Y_i$ , 则  $\zeta_{nn} + X_n = S_n, \zeta_{n1} + Y_1 = B_n \cdot N(0, 1), \zeta_{nk} + X_k = \zeta_{n,k+1} + Y_{k+1}$ , 利用逐项相消, 可将  $X_i$  替换为  $Y_i$ :

$$E \left[ g \left( \frac{S_n}{B_n} \right) \right] - E[g(Y)] = \sum_{k=1}^n \left( E \left[ g \left( \frac{\zeta_{nk} + X_k}{B_n} \right) \right] - E \left[ g \left( \frac{\zeta_{nk} + Y_k}{B_n} \right) \right] \right)$$

再利用  $\zeta_{nk}, X_k, Y_k$  独立泰勒展开估算  $h(t) = \sup_x \{g(x+t) - g(x) - g'(x)t - \frac{1}{2}g''(x)t^2\}$ , 拆分证明。

### §7.3 随机矩阵

#### 1. 起源

统计 (样本协方差阵):

$X_k = (X_{1k} \cdots X_{pk})^T, X = (X_1 \cdots X_n)$  为  $p \times n$  矩阵。

当  $X_{ij}$  独立同  $N(0, 1)$  时,  $X$  的联合密度  $f(X) = \frac{1}{\sqrt{2\pi}^{pn}} \exp \left( -\frac{1}{2} \text{tr}(XX^T) \right)$

物理: 波函数、随机矩阵模拟

#### 2. 高斯正交系综 (Gaussian Orthogonal Ensemble)

$X_n: \Omega \rightarrow M_{n \times n}(\mathbb{R}), X_n(\omega) = (x_{ij}(\omega))_{i,j=1}^n$

$x_{ij}$  独立同  $N(0, \sigma^2)$ , 记  $A_n = \frac{X_n + X_n^T}{2}$ , 计算可发现  $a_{ii} \sim N(0, \sigma^2), a_{ij} \sim N\left(0, \frac{\sigma^2}{2}\right) (i \neq j)$ , 且  $A_n$  的上半三角部分独立, 由此直接计算乘积可知  $A_n$  (上半三角) 的分布:

$$f(A_n) = 2^{-n/2} (\pi \sigma^2)^{-n(n+1)/4} \exp \left( -\frac{1}{2\sigma^2} \text{tr} A_n^2 \right), \text{ 记为 } A_n \sim \text{GOE}_n(\sigma)$$

\* 正交变换下不变性:  $Q$  为正交阵,  $B_n = Q^T A_n Q$ , 则  $B_n \sim \text{GOE}_n(\sigma)$

#### 3. 半圆律

$X$  分布函数  $\omega(x) = \frac{1}{2\pi} \sqrt{4-x^2}$ , 记  $\gamma_k = E[X^k]$ , 计算知其为  $\begin{cases} 0 & k = 2m+1 \\ \frac{1}{m+1} C_{2m}^m & k = 2m \end{cases}$ 。

实 Wigner 矩阵:  $A_n = (a_{ij})$  为实对称阵,  $a_{ii}$  独立与  $Y$  同分布,  $a_{ij} (i > j)$  独立与  $z$  同分布,  $E[Y] = E[Z] = 1, \text{Var}(Z) = 1, \text{Var}(Y) < \infty, |Y|, |Z|$  各高阶矩存在。

**定理 7.6**  $k \in \mathbb{N}, \frac{1}{n} E \left[ \text{tr} \left( \frac{A_n}{\sqrt{n}} \right)^k \right] \rightarrow \gamma_k$

证明: 左 =  $n^{-1-k/2} \sum_{i_1, \dots, i_k} E[a_{i_1 i_2} a_{i_2 i_3} \cdots a_{i_k i_1}]$ , 类似定理 5.14 可证明不消失的项中必然每个不同的  $a_{ij}$  出现两次, 进而说明  $i_1, \dots, i_k$  选取方法与  $1, 2, \dots, k$  不相交 (对任何  $a < b < c < d$ , 不存在配对  $(a, c), (b, d)$ ) 的两两配对数 ( $k = 2m$  时即为卡特兰数  $C_m$ ) 一一对应, 再利用组合计算知结论。

#### 4. Wishart 矩阵模型

$X = (x_{ij})_{p \times n}$ , 矩阵元独立同  $N(0, 1)$ , 设  $n - p = \alpha$  固定, 则  $\frac{1}{p} E \left[ \text{tr} \left( \frac{1}{p} X X^T \right)^m \right] \rightarrow C_m$ 。